Universidade Federal do Rio Grande do Sul
Instituto de Pesquisas Hidráulicas – IPH
Programa de Pós-Graduação em Recursos Hídricos e Saneamento Ambiental

Iporã Brito Possantti

Sobre o Uso de Modelos Hidrológicos no Planejamento da Revitalização de Bacias Hidrográficas

Porto Alegre
2024

Iporã Brito Possantti

Sobre o Uso de Modelos Hidrológicos no Planejamento da Revitalização de Bacias Hidrográficas

Tese apresentada ao Programa de Pós-graduação em Recursos Hídricos e Saneamento Ambiental da Universidade Federal do Rio Grande do Sul, como requisito parcial à obtenção do grau de doutor.

Orientador: Prof. Dr. Guilherme Fernandes Marques

Conteúdo

Siglas **vi**

Nomenclatura **vii**

0 Resumo **1**

1 A vista da montanha – fundamentos filosóficos **3**

1.1 Introdução 3
1.2 Justificação 5
1.3 Confirmação 7
1.4 Rejeição 16
1.5 Paradigmas 20
1.6 Subdeterminação 22
1.7 Resumo do capítulo 28

Glossário **29**

Lista de Figuras

1.1 De circuitos eletrônicos para processos hidrológicos 4
1.2 Exemplo do condicionamento Bayesiana 11
1.3 Primeira etapa de condicionamento de um modelo linear 13
1.4 Segunda etapa de condicionamento de um modelo linear 14
1.5 Erro aditivo e erro multiplicativo 15
1.6 Bandas de incerteza de vazão a partir de curvas-chave 16
1.7 Critérios de rejeição para seleção de modelos 19
1.8 Abordagem instrumentalista para a modelagem hidrológica 26

Lista de Tabelas

1.1 Espaço de possibilidades do exemplo do aeroporto 8
1.2 Exemplo condicionamento objetivo 10
1.3 Exemplo de condicionamento subjetivo 10

Siglas

GCD Greatest Common Divisor. 1

LCM Least Common Multiple. 1

Nomenclatura

Capítulo 1

μ	Média
Ω	Espaço de possibilidades
σ^2	Variância
Θ	Vetor de parâmetros
Υ	Vetor de dados de entrada
ε	Erro
E	Evidência
H	Hipótese
M	Modelo
n	Tamanho amostral
O	Observação
P	Probabilidade
S	Enunciado
s^2	Variância amostral

Hidrologia

Q	Vazão

Capítulo 0

Resumo

Lorem ipsum dolor sit amet consectetur adipiscing elit. Sed ac bibendum orci. Cras erat elit, consequat vel erat ac, tincidunt pulvinar lacus. Pellentesque vitae consectetur quam. Interdum et malesuada fames ac ante ipsum primis in faucibus. The typesetting markup language is specially suitable for documents that include . Given a set of numbers, there are elementary methods to compute its Greatest Common Divisor, which is abbreviated GCD. This process is similar to that used for the Least Common Multiple (LCM).

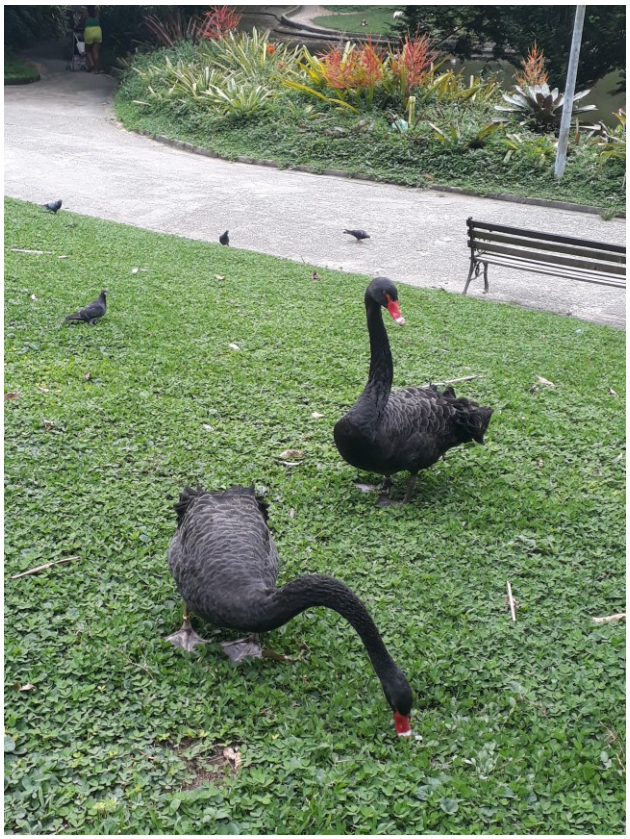

Em 16 de Fevereiro de 2023, às 15 horas e 23 minutos, dois cisnes negros foram observados no parque aos fundos do Palácio das Laranjeiras, Rio de Janeiro, Brasil. Um único cisne negro já seria suficiente para provar que nem todos os cisnes são brancos.

Capítulo 1

A vista da montanha – fundamentos filosóficos

É claramente possível desenvolver e usar modelos ambientais sem nenhuma filosofia subjacente. Muitos praticantes o fazem, ainda que a maioria no fundo talvez queira desenvolver e usar modelos que sejam "o mais realistas possíveis", dadas as restrições do conhecimento atual, das capacidades computacionais e das tecnologias de observação.

Keith Beven, 2009

1.1 Introdução

Simular um modelo hidrológico consiste em aplicar voltagens sobre circuitos eletrônicos. É *literalmente* isso que acontece durante uma simulação. A forma e a ordem como as voltagens são aplicadas correspondem diretamente às instruções codificadas fornecidas para a unidade de processamento central da máquina que estamos operando, normalmente um computador digital. Nesse caso, fornecemos ao sistema operacional um código em uma linguagem de alto nível (como Fortan ou Python) que é interpretado para uma versão de baixo nível, processável pela máquina. Com isso, todas as informações, incluindo dados e instruções, são convertidas em dígitos binários (*bits*) armazenados por estados de circuitos eletrônicos denominados transistores. O processamento, por sua vez, acontece através de portas lógicas que executam operações *booleanas* de conjunção $\wedge$, disjunção $\vee$ e negação $\neg$ sobre os bits. Os gráficos, mapas e animações que vemos após uma simulação se referem objetivamente aos estados gravados de trechos da memória digital dessa máquina - números representados na forma binária por transistores. Dito isso, como é possível que padrões binários em circuitos digitais tenham *alguma coisa a ver* com a chuva, a vazão dos rios ou a umidade no solo?

Como destacado por Keith Beven na epígrafe do capítulo, são raras as aplicações de modelos hidrológicos[1] que fundamentam essa questão com uma *filosofia explícita* [1]. Mesmo assim, os usuários de modelos em geral acreditam que os resultados das simulações oferecem uma *representação realista* de processos e fenômenos que de fato existem no mundo, não apenas nos circuitos eletrônicos, como a erosão dos solos, o escoamento dos rios, a transpiração das plantas, etc. É claro, ninguém pensa que as

[1] Ainda que Beven na verdade se refira a modelos ambientais em geral, incluindo modelos atmosféricos e geoquímicos, irei aqui circunscrever a discussão aos modelos hidrológicos.

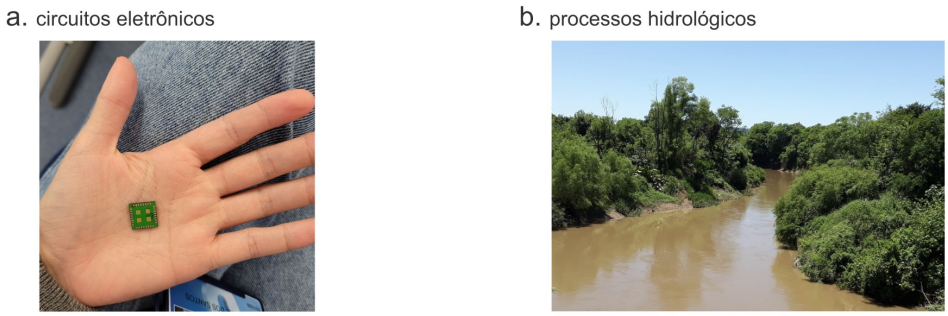

Figura 1.1 — De circuitos eletrônicos para processos hidrológicos. a.— Aplicar um modelo hidrológico consiste em *literalmente* aplicar voltagens em circuitos eletrônicos digitais. Os resultados das simulações se referem literal e objetivamente ao processamento dos estados binários de transistores. **b.**— Os usuários de modelos hidrológicos em geral aceitam que os resultados eletrônicos são uma *representação realista*, ainda que aproximada, de diversos processos hidrológicos, seja a infiltração da chuva, o escoamento superficial ou a vazão de um rio. Como isso é possível? Fonte das fotografias: (a.) Karina Kerne; (b.) o autor.

simulações dos modelos hidrológicos fornecem uma descrição *exata* da realidade, mas geralmente se aceita que eles asseguram uma descrição *aproximada* da realidade e que essa aproximação pode ser melhorada à medida que novas tecnologias de computação e de observação tornam-se disponíveis. Essa crença acentua-se ainda mais quando os resultados das simulações são direcionados para auxiliar na tomada de decisões importantes relacionadas com a gestão dos recursos hídricos em organizações do Estado ou de empresas privadas. Se recursos materiais e humanos são alocados com base nesses resultados, é bom mesmo que eles concordem com a realidade!

Beven denomina essa filosofia implícita comum entre os usuários de modelos hidrológicos de **realismo pragmático**. Ele classifica essa postura como ingênua, demonstrando que a tão almejada representação realista, quando levada a sério, torna-se um objetivo extraordinário diante da **incerteza empírica** que existe na modelagem hidrológica. Se a gestão dos recursos hídricos deseja honestamente construir **políticas baseadas em evidências**, o aconselhamento científico deve adotar uma *postura crítica* em relação ao uso de modelos e de seus resultados. Como destacado por Ongaro e Andreoletti, a incerteza é um atributo pervasivo no processo de tomada de decisão [2]. Nesse contexto, eles argumentam que o papel adequado das autoridades científicas é informar sobre as incertezas empíricas para que outros grupos de interesse[2] possam deliberar sobre as incertezas éticas e as incertezas políticas em jogo. Mas essa postura crítica só é possível a partir de uma perspectiva filosófica explícita, denominada aqui de **instrumentalismo**, que traz à tona diversos problemas que precisam ser endereçados antes de afirmarmos a correspondência entre voltagens em circuitos eletrônicos e processos hidrológicos em bacias hidrográficas.

Com esse espírito, o objetivo deste capítulo é estabelecer os fundamentos filosóficos instrumentalistas que serão utilizados explicitamente ao longo desta tese. Irei aqui abordar as seguintes questões básicas da Filosofia da Ciência: o problema da justificação, a epistemologia Bayesiana, a falseabilidade de teorias, o conceito de paradigmas e o problema da subdeterminação. A ontologia de modelos, que também é um tema pertinente, será tratada no próximo capítulo. Para os propósitos deste capítulo, deve-se considerar que **um modelo é um veículo simbólico de uma teoria**. A intenção não é esgotar os temas apresentados (até porque isto iria demandar a escrita de muitas outras teses!). Ao contrário, deve-se entender o capítulo como uma **visão panorâmica**, como se estivéssemos no topo de **uma montanha**. Essa analogia é particularmente

[2] Tradução livre de *stakeholders*

útil, pois o cume propicia uma boa compreensão da paisagem que se estende abaixo de nossos pés. Ao mesmo tempo, é um território inóspito. O ar é rarefeito, sentimos vertigens. A locomoção é complicada, possível apenas por labirintos de trilhas cercadas de precipícios e cavernas. É preciso tomar cuidado para não se perder e nunca mais voltar.

1.2 Justificação

A Epistemologia é o ramo da Filosofia que investiga a natureza do próprio conhecimento humano. Por essa perspectiva, uma **teoria** é um *enunciado universal* que providencia uma explicação definitiva sobre determinado fenômeno. Dessa maneira, criar uma teoria é relativamente fácil. Podemos professar, por exemplo, a teoria que fadas da floresta são as responsáveis por fazer objetos domésticos desaparecerem, especialmente meias. Temos um fenômeno (o sumiço de coisas) e uma explicação definitiva (as fadas). A parte difícil, contudo, é *justificar* a verdade de uma teoria – o assim denominado **problema da justificação**. Se alguém alegar que, de fato, o cachorro é o responsável por fazer as meias sumirem, como defender a teoria das fadas?

Esse problema epistemológico foi assimilado por duas correntes filosóficas diferentes durante o nascimento do método científico na modernidade [3]. Uma das correntes de pensamento, o **racionalismo**, sustenta que a *Lógica* deve ser a justificativa para a verdade de teorias. Essa posição costuma ser associada a Descartes (1596-1650), Spinoza (1632-1677) e Leibniz (1646-1716) – os ditos racionalistas continentais. Descartes, um dos maiores racionalistas de seu tempo, propagou a noção de que os sentidos são enganadores e elegeu a razão como guia de suas opiniões. Em seu *Discurso do Método*, ele chegou ao ponto de desconfiar da existência de tudo, alegando que a realidade pode ser indiscernível de um mero sonho [4]. Com isso, ele concluiu que o ato de duvidar da existência garante ao menos uma única certeza absoluta: a existência de si mesmo[3]. A outra corrente filosófica, o **empirismo**[4], defende que uma teoria justifica-se por **evidências empíricas**, ou seja, a partir de uma coleção de observações diretas de eventos e fenômenos. Essa linha de pensamento associa-se aos filósofos Locke (1632-1704), Hume (1711-1776) e Reid (1710-1796), os chamados empiristas britânicos. Locke, por exemplo, ficou conhecido por difundir as ideias de que todos nascem iguais como uma folha em branco, uma *tabula rasa*, e adquirem conhecimento pela experiência, ao interagir com seu seu ambiente [5].

O que essas correntes filosóficas favorecem, em essência, são diferentes métodos de *inferência*. Enquanto os racionalistas preferem a **inferência dedutiva**, os empiristas preferem a **inferência indutiva**. No primeiro caso, enunciados são justificados quando decorrem logicamente a partir de suas premissas, isto é, são deduzidos [6]. Por exemplo, considerando as premissas de que "*todos os gaúchos gostam de mate*" e que "*Clara é gaúcha*", então deduzimos que "*Clara gosta de mate*". Geralmente o processo de inferência dedutiva assume uma estrutura em que um enunciado condicional (se S_1 é verdade, então S_2 também é verdade) é seguido por uma sentença *antecedente*, que pode ser uma afirmação (*modus ponens*: S_1) ou uma negação (*modus tollens*: $\neg S_1$), o

[3] A ideia de Descartes de que se "penso, logo existo" (*cogito, ergo sum*) parece garantir a existência de um *self* que faz perguntas. Mas ela não garante a existência de nada *além* do *self*. Isso facilmente pode nos conduzir para o **solipsismo**: a tese de que o *self* está sozinho pairando no vazio, imaginando uma realidade que fundamentalmente não existe. Afinal, como *você*, que está lendo esse texto, tem certeza que *eu*, o autor, existo? Como garantir que todas as suas memórias não foram criadas agora, neste instante? E se a sua vida inteira não for apenas uma alucinação imaterial?

[4] Tradução livre do termo em inglês *empiricism*.

que leva à conclusão da sentença *consequente*. Na forma afirmativa (*modus ponens*):

$$\begin{array}{rll} S_1 \implies S_2 & \text{se alguém é gaúcho, então esse alguém gosta de mate} \\ S_1 & \text{Clara é gaúcha} \\ \therefore\ S_2 & \text{portanto, Clara gosta de mate} \end{array}$$

A inferência dedutiva garante a verdade da sentença consequente desde que suas premissas antecedentes sejam verdadeiras. No modo afirmativo ilustrado, ela vai no sentido de deduzir *enunciados singulares* a partir de *enunciados universais*. A inferência indutiva, ao contrário, vai no outro sentido. Os empiristas buscam construir teorias (enunciado universais) *generalizando* a partir de evidências (enunciados singulares) obtidas pela experiência empírica. Surge, assim, a noção de **hipótese**: um esboço de teoria a ser *confirmado* ou *verificado* pelas evidências. Por exemplo, se constatamos que parte da cultura dos gaúchos inclui beber mate, podemos inferir, por indução, que os gaúchos devem gostar de mate. Com um pouco mais de cautela e rigor empírico, eventualmente podemos afirmar que a *probabilidade* de um gaúcho qualquer gostar de mate é alta, uma vez que em 99% dos entrevistados em uma pesquisa com mil gaúchos afirmaram que sim, gostam de beber mate. A observação de fenômenos, para os empiristas, justifica a construção de generalizações que são plausíveis ou *prováveis*.

Ambas as linhas de raciocínio são problemáticas. O uso estrito da lógica como justificativa de teorias produz o **problema da regressão infinita** [7]: se um enunciado S_1 é justificado por outro enunciado S_2 ($S_2 \implies S_1$), o que justifica S_2? Talvez o enunciado S_3 justifique S_2 e o enunciado S_4 justifique S_3, assim por diante, *ad infinitum* ($\infty \implies ... \implies S3 \implies S_2 \implies S_1$). Uma alternativa é estabelecer um encadeamento circular de enunciados ($S_1 \implies S_2 \implies S_3 \implies S_1$), mas isso é, em termos lógicos, ainda pior que a situação anterior, pois no final das contas os enunciados se auto-justificam. A regressão infinita é facilmente percebida quando crianças, sendo naturalmente curiosas, aprendem a perguntar "*porquê?*". É possível parar a regressão (ou pelo menos *parar as perguntas*) ao se estabelecer verdades fundamentais, axiomas inquestionáveis, como acontece na Matemática. Mas na Ciência isso apenas produz teorias *dogmáticas*, baseadas em convenções, alvos fáceis para as críticas dos empiristas. Por outro lado, o uso da experiência empírica como justificativa de teorias traz consigo um problema insolúvel, descrito por David Hume (1711-1776) e conhecido hoje como **problema da indução**. A inferência indutiva é frágil porque ela se fundamenta no **princípio da uniformidade**: a suposição de que as regularidades da natureza observadas no passado serão as mesmas a serem observadas no futuro. Essa suposição é a base de toda a Física, afinal, as leis observadas hoje são usadas para prever eventos no futuro e reconstruir os eventos que já ocorreram, desde o Big Bang. Apesar de intuitivo, não é possível justificar racionalmente o princípio da uniformidade. Se evocarmos o fato de que desde sempre ele demonstrou-se funcional ou correto, incorremos em um argumento circular, logicamente inválido, que *evoca o próprio princípio da uniformidade para justificar o princípio da uniformidade* [8]. Em outras palavras, não se pode defender a inferência indutiva através de um argumento indutivo! Assim, o princípio da uniformidade é, em última instância, o dogma fundamental dos empiristas [5].

O avanço da modernidade gradualmente reduziu a rivalidade intelectual existente entre os pensadores do continente europeu e as ilhas britânicas. O empirismo, ainda que revisado e moderado, triunfou sobre o racionalismo – especialmente após a obra

[5] As ideias de Hume nos conduzem inevitavelmente para o **ceticismo**. Além do problema da indução, Hume argumentou que a **causalidade** entre fenômenos é um conceito imaginário, jamais experienciado *diretamente* na realidade. Imagine que uma bola de bilhar colida com outra bola em repouso. A seguir, a bola em repouso passa se mover também. Newton diria que isso aconteceu *por causa* da lei conservação de movimento. Mas essa lei requer diversos conceitos teóricos imaginados, como massa e energia. O que de fato podemos experienciar são eventos ocorrendo um após o outro, mas nunca a conexão de causa e efeito entre eles. Para Hume, *essa conexão não existe*.

de Immanuel Kant (1724-1804). Com sua *Crítica à Razão Pura* (1781), esse pensador propõe uma síntese entre racionalismo e empirismo. Nela, Kant concorda com os empiristas – de que a experiência empírica justifica o conhecimento – mas faz uma concessão ao racionalismo, estabelecendo que conceitos teóricos sobre os objetos a serem conhecidos são necessários *a priori*. Sem o que ele denominava de *categorias transcendentais*, não temos muito o que fazer com as percepções que coletamos sobre o mundo externo. A hegemonia do empirismo na modernidade acabou culminando no início do século XX com o movimento filosófico do **positivismo lógico**. Esse movimento estabeleceu o senso comum de que teorias científicas são *verificadas* ou *confirmadas* a partir da coleta de observações e análises estatísticas. Mas essa concepção foi ultrapassada a partir de meados do século XX, principalmente em razão das transformações impressionantes na Física. Isso reanimou o debate filosófico sobre como que a Ciência justifica suas teorias e muda elas no longo prazo, com novas perspectivas sendo propostas por Karl Popper (1902-1994) e Thomas Kuhn (1922-1996). Já no final do século XX, fatos como a crise de unificação da Física, o advento dos computadores digitais e as revelações da Biologia criaram as condições para o debate filosófico contemporâneo: Realismo científico e o propósito da Ciência.

1.3 Confirmação

Na seção anterior, vimos que a corrente empirista estabelece que uma hipótese representa um esboço de teoria que deve ser *confirmada* pelas experiência empírica. Nesse sentido, as ideias do filósofo e estatístico Thomas Bayes (1701-1761) fornecem um método de inferência indutiva particularmente útil para a confirmação de hipóteses a partir da matemática das probabilidades [9], [10]. A ideia central da chamada **epistemologia Bayesiana** professa que o conhecimento não é uma questão de tudo ou nada, preto ou branco, mas que apresenta sutilezas, com diversos tons de cinza entre o verdadeiro e o falso. A razão disso deriva do reconhecimento de que as observações empíricas estão inevitavelmente sujeitas a um **ruído aleatório**, ou seja, de que existe **incerteza estatística** nos dados amostrados. Para essa corrente empirista, as sutilezas do conhecimento consistem no **grau de convicção** [6] na verdade de uma hipótese. Esse grau de convicção deve ser atualizado à medida que **evidências** favoráveis ou desfavoráveis são obtidas pela experiência empírica.

Antes prosseguir, será útil estabelecer um exemplo intuitivo.

Considere que você está em no aeroporto de um país distante, na praça de alimentação de um agitado terminal internacional. Você deseja saber se a pessoa na mesa à sua frente vai pegar o seu mesmo voo para o Brasil. Sem nenhuma informação disponível, o seu grau de convicção nessa hipótese é relativamente baixo, pois existem dezenas de voos previstos neste terminal para diversos outros países. Mas se você desconfia que ela é brasileira, o seu grau de convicção aumenta – afinal, seu voo deve estar lotado de outros brasileiros. Ao mesmo tempo, é preciso ter cautela, pois ser brasileiro não implica necessariamente estar viajando para o Brasil. E mesmo que a pessoa não fosse brasileira, também existiria a pequena chance de estar viajando para o Brasil no mesmo voo que você, a turismo ou a negócios. Um fato é certo: *uma evidência favorável de que ela é brasileira fará você atualizar o seu grau de convicção.* A epistemologia Bayesiana articula como fazer isso de forma matematicamente precisa.

Um bom ponto de partida para formalizar o conceito de grau de convicção em termos de probabilidades é notar que uma dada hipótese H e a sua evidência favorável E se distribuem em um **espaço de possibilidades** Ω. Na perspectiva Bayesiana, se atribui para cada uma dessas possibilidades um grau de convicção que pode ser considerado probabilístico desde que elas sejam *mutuamente excludentes* (não podem

[6] Tradução livre do termo *credence* do inglês.

ser verdadeiras ao mesmo tempo) e *conjuntamente exaustivas* (pelo menos uma delas é verdadeira). Dadas essas condições, se observa então o **princípio do probabilismo** a partir dos seguintes axiomas:

- **Não-negatividade**. A probabilidade de uma dada possibilidade A deve ser um número real não-negativo: $P(A) \geq 0$;
- **Normalização**. As probabilidades de todas as possibilidades devem somar até a unidade: $P(\Omega) = 1$, e;
- **Aditividade**. Por serem incompatíveis, a probabilidade de duas possibilidades A e B é a soma das suas probabilidades individuais: $P(A \cup B) = P(A) + P(B)$.

No exemplo do aeroporto, essas possibilidades são quatro: a pessoa é brasileira e está no mesmo voo (E é verdadeira e H é verdadeira); a pessoa é brasileira e não está no mesmo voo (E é verdadeira e H é falsa); a pessoa não é brasileira e está no mesmo voo (E é falsa e H é verdadeira), e; a pessoa não é brasileira e não está no mesmo voo (E é falsa e H é falsa). Esse espaço de possibilidades pode ser visualizado mais facilmente a partir de uma tabela com números ilustrativos, como na Tabela 1.1. Assim sendo, considere que no terminal internacional existem previstos 200 voos (apenas um deles para o Brasil) e que cada avião comporta 500 passageiros. Ou seja, no total existem 100 mil passageiros circulando no terminal. Além disso, existem 800 brasileiros no terminal, sendo 450 no seu voo e outros 350 com outros destinos.

	mesmo voo (H)	**outro voo ($\neg H$)**	totais
é brasileira (E)	450	350	800
não é brasileira ($\neg E$)	50	99150	99200
totais	500	99500	100000

Tabela 1.1: Espaço de possibilidades do exemplo do aeroporto. Os números representam a distribuição de passageiros nas diferentes combinações entre hipótese H (vai no mesmo voo) e evidência E (nacionalidade é brasileira)

A inspeção da tabela nos permite facilmente perceber que a probabilidade da sua hipótese ser verdadeira, de um passageiro qualquer estar no seu voo, é de $P(H) = 0.005$ (0.5%), pois $500/100000 = 0.005$. No jargão Bayesiano, essa é a **probabilidade anterior** [7]. Mas a evidência de que essa pessoa pode ser brasileira muda tudo. Agora, a probabilidade da sua hipótese ser verdadeira dado que a evidência é verdadeira é de $P(H|E) = 0.56$ (56%), pois $450/800 = 0.56$. No jargão Bayesiano, essa é a **probabilidade posterior** [8]. O **teorema de Bayes** formaliza esse raciocínio:

$$P(H|E) = \frac{P(H) \cdot P(E|H)}{P(E)} \tag{1.1}$$

Em que $P(H|E)$ é a probabilidade da hipótese H ser verdadeira dado que a evidência E é verdadeira (**probabilidade posterior**); $P(H)$ é a probabilidade da hipótese H ser verdadeira (**probabilidade anterior**); $P(E|H)$ é a probabilidade da evidência E ser verdadeira dado que a hipótese H é verdadeira, chamada de **verossimilhança**, e; $P(E)$ é a probabilidade da evidência ser verdadeira sob todas as possibilidades. No caso do aeroporto:

$$P(H|E) = \frac{\frac{500}{100000} \cdot \frac{450}{500}}{\frac{800}{100000}} = \frac{450}{800} = 0.56\,(56\%)$$

O que o teorema de Bayes quer dizer é que a estimativa da probabilidade da hipótese ser verdadeira diante da evidência favorável deve levar em consideração tanto o espaço

[7] Tradução livre do inglês do termo *prior*
[8] Tradução livre do inglês do termo *posterior*

de possibilidades reduzido que a evidência favorável implica (no exemplo, o fato de existirem poucos brasileiros no terminal internacional) quanto de que existe a chance da evidência não garantir a hipótese (no exemplo, o fato de que nem todos no seu voo são brasileiros). Ou simplesmente:

$$\text{Posterior} = \text{Anterior} \times \text{Verossimilhança} \div \text{Evidência}$$

A atualização do grau de convicção só é possível *desde que* a evidência favorável à hipótese seja verdadeira. Por essa razão, esse é o chamado **princípio da condicionalização** da epistemologia Bayesiana. No exemplo do aeroporto, tudo é muito óbvio porque os números absolutos de passageiros foram fornecidos pela tabela. As probabilidades calculadas dessa forma são objetivas, baseadas na frequência de cada conjunto do espaço de possibilidades Ω. Mas em uma situação prática geralmente só temos acesso aos graus de convicção do espaço de possibilidades Ω, que devem mudar à medida que novas evidências são obtidas. Para manter a concordância com os axiomas do probabilismo, a condicionalização ou **condicionamento**[9] com as evidências deve *zerar*, *escalonar* e *normalizar* os valores das probabilidades. No exemplo do aeroporto, quando descobrimos que a pessoa no aeroporto é definitivamente brasileira, devemos zerar as probabilidades de que ela não é brasileira, o que implica escalonar proporcionalmente a probabilidade das outras possibilidades e *normalizar seus valores* de forma que a sua soma seja igual à unidade, pois $P(\Omega) = 1$. Por outro lado, se apenas inferirmos que a pessoa na mesa à frente fala português (talvez por estar lendo algum livro), isso não é suficiente para zerar a probabilidade dela não ser brasileira (afinal, outras nacionalidades também falam português!).

O princípio da condicionalização concede que se aplique o teorema de Bayes para um número finito de N hipóteses $H_1, \ldots, H_N$, desde que elas sejam possibilidades mutuamente excludentes e conjuntamente exaustivas. Nesse caso, o teorema de Bayes assume a seguinte forma:

$$P(H_i|E) = \frac{P(H_i) \cdot P(E|H_i)}{\sum_{j=1}^{N} P(E|H_j) \cdot P(H_j)} \tag{1.2}$$

O denominador nessa equação é uma constante que desempenha o papel de normalizar os valores das probabilidades, assegurando que $P(\Omega) = 1$. Aqui, nota-se que a normalização oportuniza se atribuir graus de convicção *não probabilísticos* para a verossimilhança $P(E|H)$ sem violar o princípio do probabilismo, desde que sejam valores não-negativos. Ou seja, a verossimilhança $P(E|H)$ pode ser interpretada como um *peso* fornecido pelas evidências. Se for o caso, a notação da verossimilhança deve ser modificada para uma **função de verossimilhança informal**, denotada por $\mathcal{L}(E|H)$. De uma forma ou de outra, a distribuição de probabilidade posterior de uma variável aleatória deve ser condicionalizada por uma distribuição de probabilidade (ou de pesos) estimada empiricamente. Para tanto, é preciso discretizar os valores da variável em N intervalos, que são as hipóteses $H_1, \ldots, H_N$ da Equação (1.2). Para cada hipótese H_i, deve-se atribuir inicialmente a sua probabilidade anterior $P(H_i)$. A seguir, evidências empíricas devem ser obtidas para se obter a verossimilhança $P(E|H_i)$ de cada hipótese. A probabilidade posterior de cada hipótese então é condicionalizada através da aplicação da Equação (1.2). Por fim, se considerarmos a distribuição posterior obtida como a distribuição anterior da próxima etapa, a confirmação da distribuição de probabilidade da variável ocorre incrementalmente à medida que novas evidências se acumulam. A Tabela 1.2 mostra um exemplo do condicionamento da distribuição de probabilidade de uma variável aleatória X, que no caso foi dividida em sete intervalos discretos delimitados pelos limiares $x_1, ..., x_6$.

[9] O termo *condicionamento* e *condicionalização* serão utilizados aqui de forma equivalente.

Hipótese i	$P(H_i)$	$P(E\|H_i)$	$P(H_i) \cdot P(E\|H_i)$	$P(H_i\|E)$
H_1: $X < x_1$	0.143	0.008	0.001	0.008
H_2: $x_1 \leq X < x_2$	0.143	0.026	0.004	0.026
H_3: $x_2 \leq X < x_3$	0.143	0.084	0.012	0.084
H_4: $x_3 \leq X < x_4$	0.143	0.171	0.024	0.171
H_5: $x_4 \leq X < x_5$	0.143	0.208	0.03	0.208
H_6: $x_5 \leq X < x_6$	0.143	0.275	0.039	0.275
H_7: $X \geq x_6$	0.143	0.227	0.032	0.227
totais	1.0	1.0	0.14	1.0

Tabela 1.2: Exemplo ilustrativo do condicionamento da distribuição de probabilidade de uma variável aleatória X. Nesse a distribuição anterior $P(H)$ foi definida como uniforme pela observação do princípio da indiferença (bayesianismo objetivo).

Hipótese i	$P(H_i)$	$P(E\|H_i)$	$P(H_i) \cdot P(E\|H_i)$	$P(H_i\|E)$
H_1: $X < x_1$	0.227	0.008	0.002	0.022
H_2: $x_1 \leq X < x_2$	0.273	0.026	0.007	0.088
H_3: $x_2 \leq X < x_3$	0.229	0.084	0.019	0.236
H_4: $x_3 \leq X < x_4$	0.146	0.171	0.025	0.306
H_5: $x_4 \leq X < x_5$	0.082	0.208	0.017	0.208
H_6: $x_5 \leq X < x_6$	0.036	0.275	0.01	0.12
H_7: $X \geq x_6$	0.008	0.227	0.002	0.022
totais	1.0	1.0	0.08	1.0

Tabela 1.3: Outro exemplo ilustrativo do condicionamento da distribuição de probabilidade de uma variável aleatória X. Nesse caso a distribuição anterior $P(H)$ foi definida subjetivamente, por opinião especialista (bayesianismo subjetivo).

Uma questão controversa no processo de condicionamento é a definição das probabilidades anteriores na primeira etapa de todas, quando ainda não existem evidências. No caso da Tabela 1.2, qual é a justificativa para a distribuição de probabilidade anterior $P(H_i)$ ser uniforme? Esse é o dito **problema dos anteriores** na epistemologia Bayesiana, que divide o campo em duas principais correntes de bayesianismo: a *subjetiva* e a *objetiva*. Para avançar, é preciso *decidir* entre uma das duas. Por um lado, a corrente do **bayesianismo subjetivo** admite qualquer distribuição de probabilidade anterior desde que ela não viole o princípio do probabilismo. O problema óbvio aqui é tornar a distribuição posterior mais sensível aos valores da distribuição anterior do que aos da própria evidência, como demonstrado na Tabela 1.3. A Figura 1.2 deixa clara diferença entre os resultados posteriores $P(H|E)$ entre as Tabelas 1.2 e 1.3, ainda que tenham sido usadas exatamente a mesma distribuição de verossimilhança $P(E|H)$ para o condicionamento. A defesa dessa corrente sustenta que é legítimo que diferentes opiniões subjetivas possam ser comparadas objetivamente. Além disso, se as evidências forem consistentes, opiniões divergentes sobre a distribuição anterior tornam-se irrelevantes no longo prazo, se dissipando durante as sucessivas etapas de condicionamento. Por outro lado, a corrente do **bayesianismo objetivo** prefere eliminar todo e qualquer viés ao se definir a distribuição anterior. Nesse intuito, se recomenda o **princípio da indiferença**: o grau de convicção em duas ou mais hipóteses deve ser igual na ausência de razões suficientes para o contrário. No caso na Tabela 1.2, talvez não existam motivos suficientes para diferenciar os valores de $P(H_i)$ e por isso foi adotada uma distribuição uniforme. Esse princípio pode até parecer natural, mas ele não passa de uma convenção arbitrária: diante da completa ignorância, qualquer distribuição de probabilidade anterior é igualmente provável, sendo a distribuição uniforme na verdade um caso extremamente específico.

Outra questão em aberto no processo de condicionamento é como se obter a verossimilhança $P(E|H)$ a partir das evidências. Afinal, sem detalhes precisos sobre todo o espaço de possibilidades Ω, como no exemplo do aeroporto, as evidências em geral

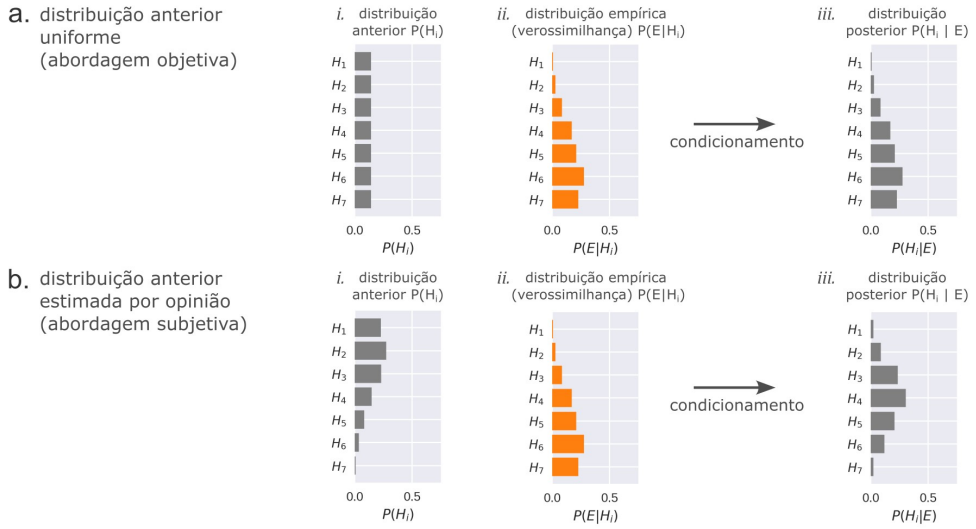

Figura 1.2 — Condicionamento da distribuição anterior de uma variável aleatória. Aqui são apresentados visualmente os dados ilustrativos das Tabelas 1.2 e 1.3. Em ambos os casos a evidência é a mesma, o que muda são as premissas utilizadas na distribuição anterior. **a.**— Distribuição uniforme, considerando o *princípio da indiferença* do bayesianismo objetivo. **b.**— Distribuição definida por opinião, prática considerada válida no bayesianismo subjetivo.

consistem em dados amostrados que não se traduzem automaticamente em probabilidades. Isso se agrava ainda mais no caso de uma variável aleatória contínua, quando buscamos estimar uma distribuição de probabilidades a partir dos dados disponíveis. Assim como no problema dos anteriores, a solução para essa questão requer uma tomada de decisão, que é se estabelecer um conjunto de premissas sobre *o comportamento do ruído aleatório*[10]. Nesse rumo, um exemplo particularmente útil para nossa discussão futura sobre modelos hidrológicos é o ajuste de curvas matemáticas que relacionam dois fenômenos, como no caso das **curvas-chave** que descrevem a vazão em função do nível observado em uma seção de rio (ver Destaque 1.3). Nesse caso, a curva matemática consiste na hipótese, ou **modelo**, que estamos interessados em saber o grau de convicção. Uma relação geral para esse problema é a seguinte [11]:

$$O(x,t) = M(x,t,\Theta) + \varepsilon(x,t) \tag{1.3}$$

Em que $O(x,t)$ é a observação empírica obtida na variável independente x e no tempo t; $M(x,t,\Theta)$ são as predições do modelo M em x,t dado o vetor de parâmetros Θ, e; $\varepsilon(x,t)$ é o **erro**[11] da observação empírica em x,t. É claro que, nesse contexto, as variáveis aleatórias de interesse para se estimar a verossimilhança do modelo M são os próprios parâmetros Θ. Um conjunto de premissas típicas[12] sobre o comportamento do ruído aleatório é que o erro ε apresenta:

1. média zero, isto é, $\mu_\varepsilon = 0$;
2. variância σ_ε^2 constante (estável);
3. independência no tempo, e;

[10] Um fato irônico da abordagem Bayesiana é que a hipótese sobre o comportamento do ruído só pode ser justificada pela lógica, nunca pelas evidências, sob pena de se adentrar em uma regressão infinita de decisões sobre o ruído do ruído. Afinal, para justificar com base em evidências a hipótese sobre o ruído aleatório, teríamos que repetir o método Bayesiano *ad infinitum*, avaliando o ruído do ruído, e o ruído do ruído do ruído, assim por diante.

[11] Também denominado de **resíduo**.

[12] A introdução de viés, autocorrelação no tempo e outras distribuições também podem ser feitas dentro de um tratamento matematicamente formal, ainda que mais intricado.

4. distribuição normal: $p(\varepsilon) = \frac{1}{\sigma_\varepsilon\sqrt{2\pi}} e^{-(\varepsilon-\mu_\varepsilon)^2/(2\sigma_\varepsilon^2)}$, em que μ_ε é a média do erro (zero) e σ_ε é o desvio padrão do erro.

A justificativa racional para considerar a distribuição normal se fundamenta no **teorema do limite central**, que estabelece que a média amostral de uma população qualquer é uma população normalmente distribuída[13]. Com isso, o problema da verossimilhança dos parâmetros Θ se resolve ao se estimar a variância populacional do erro σ_ε^2 pela sua variância amostral, que é definida por $s_\varepsilon^2 = \frac{1}{df}\sum_{i=1}^{n}(\varepsilon_i - \bar{\varepsilon})^2$, em que $\bar{\varepsilon}$ é a média amostral do erro; n é o tamanho amostral, e; df é o número de graus de liberdade[14] [12]. O erro ε_i de cada n observação é a diferença entre a observação O_i e a predição da curva do modelo M_i definida por parâmetros Θ ajustados com técnicas de otimização, como o **método dos mínimos quadrados**. A seguir, a incerteza associada à variância do erro deve ser assimilada de alguma forma pelos parâmetros Θ. Para modelos lineares, é possível fazer isso analiticamente, a partir dos princípios da combinação linear de variáveis aleatórias. Uma alternativa robusta, aplicável para modelos em geral, é o método das **simulações de Monte Carlo**. Nesse método, são feitas inúmeras *reamostragens* do erro ε, ou seja, simulações de realizações estatisticamente equivalentes[15]. Para cada simulação, são ajustados novos valores para os parâmetros Θ por técnicas de otimização. Assim, o banco de dados gerado por essas simulações oportuniza a estimativa da distribuição de probabilidade empírica dos parâmetros Θ do modelo $M(x, t, \Theta)$, que enfim podem ser utilizadas no processo de condicionamento.

A Figura 1.3 e a Figura 1.4 apresentam um exemplo ilustrativo para o processo de condicionamento de um modelo. O objetivo foi condicionar um modelo linear do tipo $M(x, \Theta) = c_1 x + c_0$ pelas evidências empíricas disponíveis[16]. Note que $\Theta = \{c_0, c_1\}$, ou seja, o problema consiste obter a distribuição de probabilidade posterior dos parâmetros c_0 e c_1. Vejamos primeiramente o caso da situação inicial (Figura 1.3), quando a primeira amostra de dados empíricos foram obtidos ($n = 50$). Diante dos dados, o modelo $M(x, \Theta)$ foi ajustado pelo métodos dos mínimos quadrados. O valor exato obtido para os parâmetros no ajuste inicial é **irrelevante**, pois estamos interessados em obter uma distribuição de probabilidade, não valores precisos. O ajuste inicial do modelo tem a única função de produzir uma estimativa da dispersão do erro ε. Por simples inspeção visual, percebe-se que a distribuição dos erros do modelo ajustado apresenta uma boa simetria em torno do zero e uma dispersão estável. Assumindo-se então que o erro ε apresenta distribuição normal com média zero e variância constante, o método de Monte Carlo foi aplicado para mil reamostragens, que foram feitas aproximando-se a variância populacional pela variância amostral (isto é, $\sigma_\varepsilon^2 \approx s_\varepsilon^2$). Em cada simulação, novos ajustes para o modelo foram feitos, de maneira que foi possível se estimar as bandas de incerteza para o modelo $M(x, \Theta)$. Por fim, a distribuição da verossimilhança $P(E|H)$ dos parâmetros c_0 e c_1 foi estimada a partir do histograma da lista de mil valores estatisticamente equivalentes gerados pelas simulações. Como a distribuição anterior $P(H)$ era uniforme, o padrão da distribuição posterior $P(H|E)$ foi completamente influenciado pela verossimilhança. Agora vejamos a segunda etapa (Figura 1.4),

[13] O que esse teorema quer dizer é que somas de números aleatórios (note que a média é uma soma) tendem a produzir naturalmente o padrão da curva normal pela simples combinação de valores altos com valores baixos. Por exemplo, considere o lançamento de um dado não enviesado de seis faces. A probabilidade de cada face superior apresentar um dos valores do conjunto $\{1, 2, 3, 4, 5, 6\}$ é a mesma, de 1/6. Mas a probabilidade da *média* dos valores amostrados em n lançamentos tende a ser muito maior entre valores intermediários à medida que n cresce, pois valores altos são compensados por valores baixos. É esse o fato que produz o padrão de sino invertido modelado pela curva normal.

[14] $df = n - 2$ para modelos com dois parâmetros.

[15] No caso de amostras pequenas, com $n < 30$, deve-se simular o erro ε pela distribuição t de *Student* com $n - 1$ graus de liberdade.

[16] Os dados aqui são sintéticos, gerados com o intuito de ilustrar a abordagem Bayesiana.

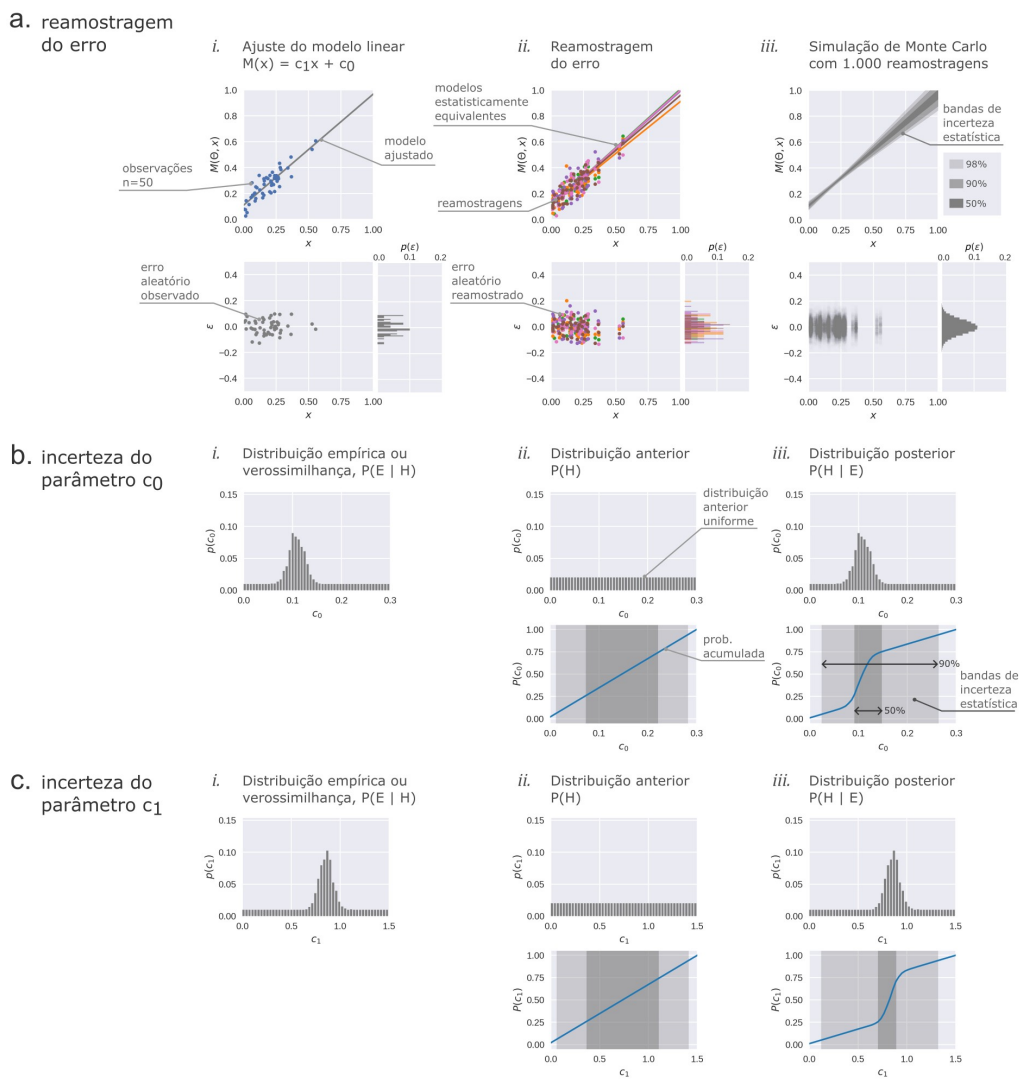

Figura 1.3 — Primeira etapa de condicionamento de um modelo linear do tipo $M(x, \Theta) = c_1 x + c_0$. a.— Ajuste de um modelo linear pelo método dos mínimos quadrados. Esse primeiro ajuste permite que se estime o comportamento do erro ε (detalhe a.*i.*). Se as premissas sobre o erro forem atendidas, são realizadas inúmeras reamostragens do erro (simulações de Monte Carlo, detalhes a.*ii.* e a.*iii*). Para cada reamostragem, novos modelos são ajustados. O banco de dados das reamostragens permite a estimativa da distribuição de probabilidade empírica dos parâmetros c_0 e c_1. **b.—** Aplicação do Teorema de Bayes para se obter a distribuição posterior do parâmetro c_0 (detalhe b.*iii.*). A distribuição empírica (detalhe b.*i.*) foi obtida pelos resultados da simulação de Monte Carlo. **c.—** Aplicação do Teorema de Bayes para se obter a distribuição posterior do parâmetro c_1 (detalhe c.*iii.*). A distribuição empírica (detalhe c.*i.*) foi obtida pelos resultados da simulação de Monte Carlo. Em ambos os casos a distribuição anterior foi considerada uniforme (b.*ii.*; c.*ii.*).

quando uma nova amostra de dados empíricos foi inserida ($n = 50$). Nessa etapa, os novos dados foram misturados aos antigos e se procedeu da mesma forma que antes: um modelo foi ajustado aos dados e novas simulações do erro ε foram feitas aproximando-se a sua variância populacional pela sua variância amostral. A exceção consistiu no fato de que a distribuição anterior agora é justamente a distribuição posterior obtida na situação inicial. Com isso, o advento de novas observações empíricas podem tanto *reforçar* quanto *atenuar* o grau de convicção obtido anteriormente para os parâmetros c_0 e c_1. No caso ilustrado, é evidente que as novas observações atenuaram suavemente o grau de convicção no caso do parâmetro c_1, alargando um pouco a banda de incerteza de 50% obtidas na primeira etapa e gerando uma distribuição posterior bimodal.

Na Equação (1.3) está embutida a premissa de que o erro ε é *linearmente aditivo* ao modelo. Mas ele poderia ser *multiplicativo*, o que faria a Equação (1.3) assumir a

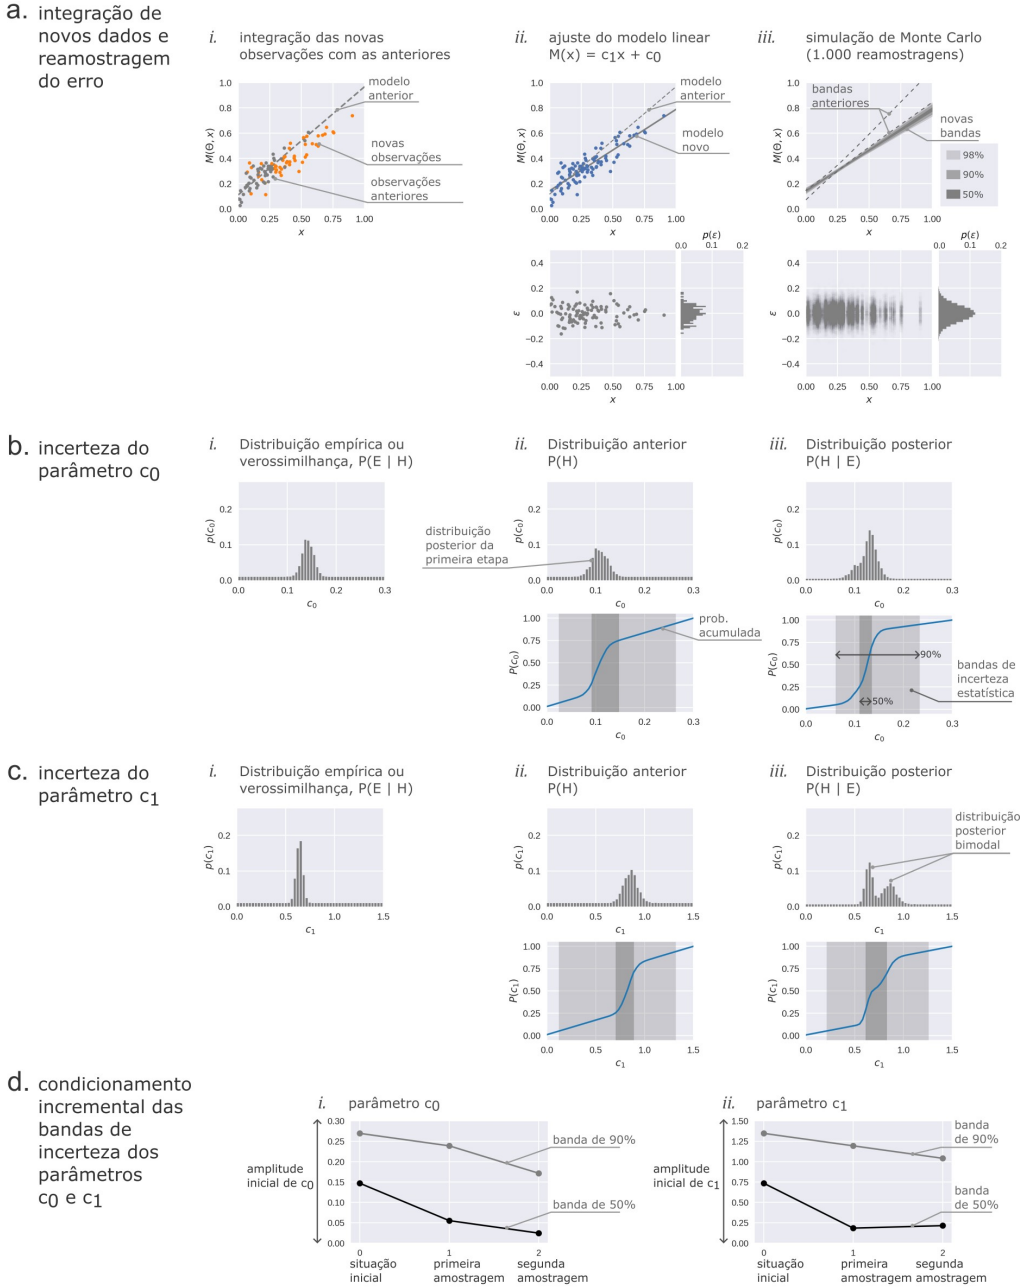

Figura 1.4 — Segunda etapa de condicionamento de um modelo linear do tipo $M(x, \Theta) = c_1 x + c_0$. a.— Segunda etapa de condicionamento. Os mesmos procedimentos são realizados como na primeira etapa, com a diferença que novos dados obtidos são integrados às observações anteriores e que a distribuição anterior utilizada é a distribuição posterior da primeira etapa. **b.—** Aplicação do Teorema de Bayes para se obter a distribuição posterior do parâmetro c_0. **c.—** Aplicação do Teorema de Bayes para se obter a distribuição posterior do parâmetro c_1. **d.—** Análise das bandas de incerteza dos parâmetros à medida que novas amostragens são feitas. As bandas de incerteza das predições e dos parâmetros do modelo foram reduzidas, com exceção da banda de incerteza de 50% na segunda etapa do parâmetro c_1. Isso aconteceu porque as evidências na segunda amostragem são muito discordantes daquelas obtidas na primeira amostragem, resultando em uma distribuição posterior bimodal (detalhe c.*iii.*).

seguinte forma:

$$O(x, t) = M(x, t, \Theta) \cdot \varepsilon(x, t) \tag{1.4}$$

Essa premissa faz sentido quando o ruído aleatório é cada vez maior à medida que a variável independente cresce. No caso das curvas-chave, é razoável esperar que erros proporcionalmente maiores estejam presentes na medição de vazões altas a partir do nível d'água, principalmente (mas não somente) em razão das maiores incertezas na geometria e rugosidade da seção do canal. Quando isso ocorre, a variância do erro não

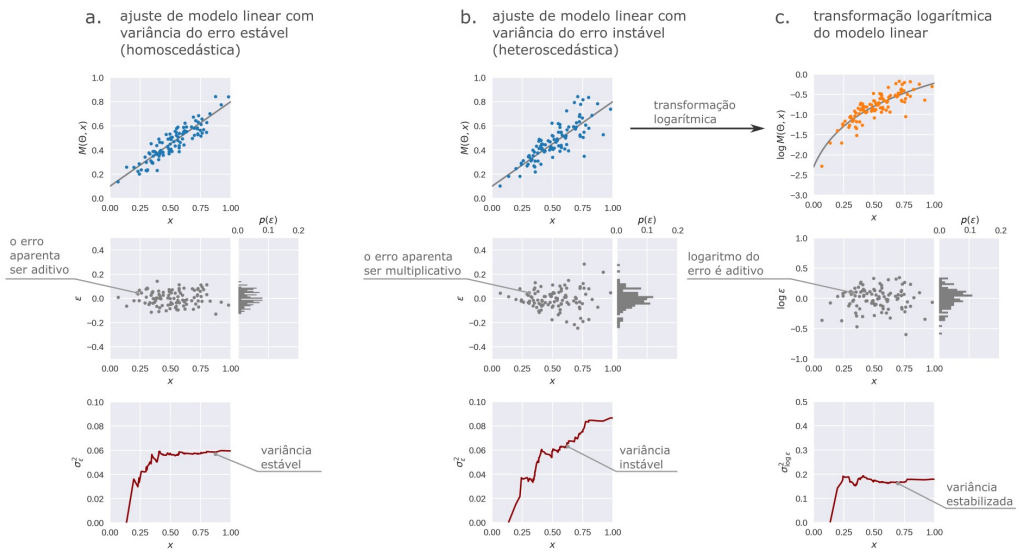

Figura 1.5 — Erro aditivo e erro multiplicado no ajuste de um modelo linear **a.**— Erro aditivo em um modelo linear, com variância do erro estável (homoscedástica). **b.**— Erro multiplicativo em um modelo linear, com variância do erro instável (heterocedástica). **c.**— Estabilização da variância do erro multiplicativo a partir de uma transformação logarítmica. O logaritmo do erro é aditivo.

é constante, mas aumenta gradativamente. Nesse caso, a variância é heteroscedástica (instável), ao contrário de homoscedástica (estável). Uma alternativa para abordar esse caso é através da **transformação de variáveis**, convertendo o problema para um caso aditivo ao se tomar o logaritmo em ambos os lados da Equação (1.4), pois $\log(ab) = \log(a) + \log(b)$. Com isso, as premissas mencionadas anteriormente podem ser avaliadas sobre $\log(\varepsilon)$, que possivelmente apresenta variância estável. Para aplicar o método de Monte Carlo, as reamostragens do erro podem ser feitas diretamente em $\log(\varepsilon)$ e convertidas de volta na Equação (1.4) para o ajuste do modelo $M(x, \Theta)$ por técnicas de otimização.

Destaque 1.3.1– Bandas de incerteza de vazão a partir de curvas-chave

A **vazão** em rios quase nunca é medida diretamente, pois para isso é preciso uma equipe técnica especializada. É muito mais fácil e barato observar o **nível** dos rios a partir de réguas linimétricas. De fato, o nível de muitos rios no Brasil é observado duas vezes ao dia em estações fluviométricas da Rede Hidrometeorológica Nacional. Assim, as raras observações de vazão factíveis são utilizadas na construção de uma **curvas-chave**, que geralmente é um modelo matemático do tipo potência:

$$Q = a \cdot (h - h_0)^b$$

Em que Q é a vazão em m^3/s; h é o nível observado, e; h_0, a e b são os parâmetros do modelo. Essa curva pode então ser usada para a estimativa da vazão a partir das observações rotineiras de nível.

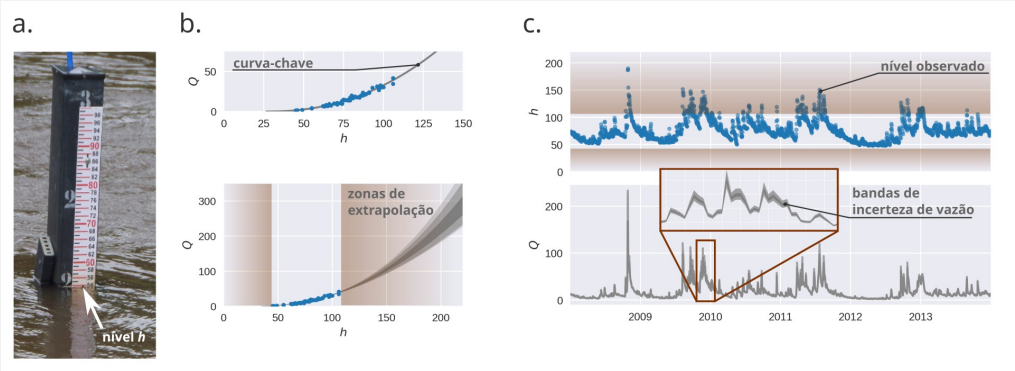

Figura 1.6 — **Bandas de incerteza de vazão a partir de curvas-chave. a.**— Observação de nível h em uma régua linimétrica. **b.**— Ajuste de um modelo tipo potência e estimativa da incerteza por métodos de reamostragem do erro. **c.**— Série histórica de nível e bandas de incerteza da vazão.

Como ilustrado na Figura 1.6, a confirmação desse modelo diante das evidências de nível e vazão inicia-se por ajustar os parâmetros aos dados disponíveis com técnicas de otimização. O comportamento do erro aleatório pode ser então avaliado. A variância do erro, se estabilizada, permite reamostragens estatisticamente equivalentes dos dados (simulações de Monte Carlo). As bandas de incerteza da curva-chave, assim, se refletem na incerteza da estimativa na série histórica de vazão. No exemplo apresentado, nota-se que existem **zonas de extrapolação** nos extremos, onde a incerteza se expande desproporcionalmente. Isso é esperado, pois eventos extremos de vazão são raros ou difíceis de serem medidos. Por outro lado, a captura de poucos eventos extremos pode reduzir drasticamente a incerteza nessas zonas.
Uma abordagem interessante nesse contexto é apresentada por Thomas Morlot e colegas, que salientam que além das incertezas estatísticas, as curvas-chave apresentam uma dependência temporal associada à mudança na morfologia da seção do rio [13]. Outras complexidades também existem, como a histerese hidráulica que pode se manifestar sob diferentes regimes de escoamento.

1.4 Rejeição

Apesar do sucesso do empirismo como corrente hegemônica na Filosofia da Ciência na modernidade, as mudanças impressionantes na Física no século XX deram mais uma chance ao racionalismo, ou seja, para a abordagem dedutiva em relação ao problema da justificação. O impacto da obra de Albert Einstein (1879-1955) é um bom exemplo desse momento histórico. No caso, Einstein revolucionou a Física a partir do que ele chamava de *experimentos mentais*. Se teorias são produto da experiência empírica,

como clamam os empiristas, Einstein jamais teria escrito seus primeiros artigos, pois na época trabalhava em uma empresa de patentes e não tinha acesso a laboratórios ou outros recursos para coletar dados empíricos. Ao contrário, foram outros cientistas que, com observações e experimentos, deram suporte para a teoria de Einstein *a posteriori*, ou seja, *depois* que as suas ideias já estavam publicadas. Algo estava definitivamente errado na corrente empirista de justificação de teorias.

O expoente desse novo movimento racionalista foi o filósofo Karl Popper (1902-1994), especialmente com sua obra *A Lógica da Pesquisa Científica*. Ele introduziu a corrente hoje denominada de **racionalismo crítico**. Por um lado, Popper estava ciente da gravidade do problema da indução, que permaneceu (e permanece) sem solução desde sua formulação por Hume – para ele, o empirismo indutivista claramente não poderia se sustentar. Por outro, as correntes filosóficas de sua época ditas Convencionalistas também não o agradavam, ainda que representassem abordagem dedutivas para a justificação de teorias. Nesse sentido, Popper analisou profundamente a lógica da pesquisa científica e concluiu que o grande poder epistêmico das evidências empíricas é justificar, pelo método dedutivo, a *falsidade* de uma teoria. Ou seja, é pela **rejeição**[17] de teorias pelas evidências que o conhecimento verdadeiro é obtido. Um exemplo simples transmite a força desse argumento. Considere o enunciado universal de que "*todos os cisnes são brancos*". Para estabelecer definitivamente a verdade desse enunciado pelo método indutivo, seria preciso observar todos os cisnes que existem no universo, inclusive cisnes no passado e no futuro, o que é obviamente impossível na prática. Por outro lado, só é preciso avistar um *único cisne negro uma única vez* no tempo e no espaço para refutar definitivamente a teoria de que todos os cisnes são brancos. Afinal, se o enunciado singular "*um certo cisne é negro*" é verdadeiro (pois foi verificado empiricamente), então deduzimos que o enunciado universal "*todos os cisnes são brancos*" é falso:

$S_1 \implies S_2$	se todos os cisnes são brancos, então um certo cisne é branco
$\neg S_2$	um certo cisne **não** é branco
$\therefore \neg S_1$	portanto, nem todos os cisnes são brancos

Esse modo de lógica dedutiva, por envolver a negação, chama-se *modus tollens*, ao contrário do *modus ponens*, que envolve a afirmação positiva. O que Popper demonstra é que existe uma assimetria fundamental entre esses dois modos de lógica quando queremos deduzir enunciados universais a partir de enunciado singulares (fazer generalizações a partir de observações pontuais), sendo o *modus tollens* a única forma de se obter conhecimento seguro (no caso, a falsidade de um enunciado universal). Daí decorre que as observações e experiências empíricas são importantes para refutar teorias, não para confirmá-las. Enquanto uma teoria sobrevive a rigorosos testes empíricos, se diz que essa teoria é *corroborada* pelas evidências empíricas – mas nunca confirmada.

Alicerçado com esse argumento, Popper se volta para o que ele chama de **problema da demarcação**, trazido inicialmente por Kant: a dificuldade de distinguir se uma teoria é *científica* ou é *apenas metafísica*, baseada unicamente em abstrações puras. Ao contrário dos empiristas, que alegam que a experiência é a origem de todo o conhecimento, para Popper a origem de onde as teorias surgem é irrelevante. Desde que sejam logicamente consistentes, elas podem se manifestar tanto a partir de alguma observação empírica motivadora (como no exemplo dos cisnes brancos), quanto a partir da intuição criativa (como os experimentos mentais feitos por Einstein). O que é relevante é a capacidade da teoria não sobreviver aos testes da experiência empírica, ou seja, a capacidade de ser rejeitada. Essa capacidade, que se denomina **falseabilidade**, é o *critério de demarcação* que categoriza uma teoria como científica. Resumidamente, na ótica do racionalismo crítico, uma teoria científica deve ser falseável. Aqui, é importante frisar que *ser falseável* não quer dizer *ser falsa*. Ser falseável significa que

[17] Aqui o termo *rejeição*, *refutação* e *falsificação* são usados de forma equivalente.

a estrutura da teoria autoriza que observações possam ser usadas para demonstrar a sua eventual falsidade. Se *por princípio* é impossível provar que uma teoria é falsa a partir de observações ou experimentos, então essa teoria não é científica. Isso geralmente implica que teorias científicas devem ser precisas o suficiente para produzirem predições observáveis. No caso de Einstein, sua teoria era precisa e fazia predições observáveis que foram, no jargão de Popper, *corroboradas* por outros cientistas (mas que poderiam ter sido perfeitamente refutadas). Já um exemplo intuitivo de teoria não falseável é a teoria do Multiverso, uma teoria cosmológica que postula a existência de Universos paralelos ao que habitamos. Por mais sedutora que seja para explicar alguns mistérios cosmológicos, essa teoria não é científica pois não autoriza nenhum teste com observações empíricas – por definição, não há como observar além de nosso próprio Universo. Nas palavras de Popper: "*uma teoria é algo que o entendimento tenta prescrever à natureza; algo que a natureza frequentemente não permite que se prescreva a ela; uma hipótese que nós tentamos impor à natureza, mas que pode ser desmentida por ela*" [14].

Uma vez designada a falseabilidade como critério de demarcação de teorias científicas, Popper avança para o então chamado **problema da simplicidade**. Esse problema epistemológico consiste na dificuldade de explicar por que se deve preferir teorias mais simples do que teorias mais complexas (também conhecido por *Navalha de Occam*). Por exemplo, considere uma série de observações pontuais de um dado fenômeno dispostas em um sistema de coordenadas. Se existe uma lei teórica que descreve esse fenômeno, essa lei será uma curva que liga todos os pontos observados. Só que para um número finito de pontos sempre é possível ajustar um número infinito de curvas com as mais diversas fórmulas matemáticas. Se uma reta apresentar um bom ajuste, isso também é possível com a parte assintótica de uma hipérbole. Como vimos na seção anterior, ainda que os empiristas Bayesianos possuem métodos para atualizar o grau de convicção no ajuste de uma dada curva à medida que novas observações são coletadas, eles não têm nada a dizer sobre a justificativa de ter *escolhido essa curva em primeiro lugar*, a não ser a sua suposta *simplicidade*. Esse é de fato um problema confuso, pois depende do que queremos dizer com o conceito de simplicidade. Para uns, significa um aspecto estético, algo relacionado à elegância matemática – como o fato de órbitas circulares para os planetas parecerem mais bonitas que órbitas elípticas. Para outros, quer dizer um aspecto pragmático, algo relacionado à economia de tempo e recursos – um método mais fácil para resolver uma tarefa deve ser preferido do que um método mais intrincado. O estatístico George Box, por exemplo, defende o que ele chama de **princípio da parcimônia** em modelos matemáticos por critérios puramente práticos, como a carga cognitiva, melhor precisão e objetividade [11].

Em vista disso, Popper elimina qualquer caráter estético ou pragmático, igualando a simplicidade de uma teoria com o seu **grau de falseabilidade**: quanto mais simples, mais falseável. Isso resolve logicamente o problema da simplicidade, pois, nas suas palavras: "*os enunciados simples (...) nos dizem mais, porque encerram um conteúdo empírico maior e porque são suscetíveis de testes mais rigorosos*" [15]. Ou seja, enquanto uma teoria mais simples, que é mais *restritiva*, sobreviver aos testes empíricos, não faz sentido lógico adotar uma teoria menos simples, que é mais *flexível*. Isso fica mais claro em termos matemáticos, pois o número de parâmetros de uma curva está inversamente associado ao seu grau de falseabilidade. Considere uma curva com três parâmetros, como um polinômio de segundo grau (uma parábola): $f(x) = c_2x^2 + c_1x + c_0$. Essa curva é muito mais flexível para ajustar dados que uma curva com dois parâmetros, como um polinômio de primeiro grau (uma reta): $g(x) = c_1x + c_0$. Afinal, se fizermos o parâmetro quadrático c_2 suficientemente pequeno, podemos ajustar igualmente bem os dados de uma linha reta $g(x)$ sem falsear a teoria que o fenômeno estudado é descrito pela parábola $f(x)$, pois $\lim_{c_2 \to 0} f(x) = g(x)$.

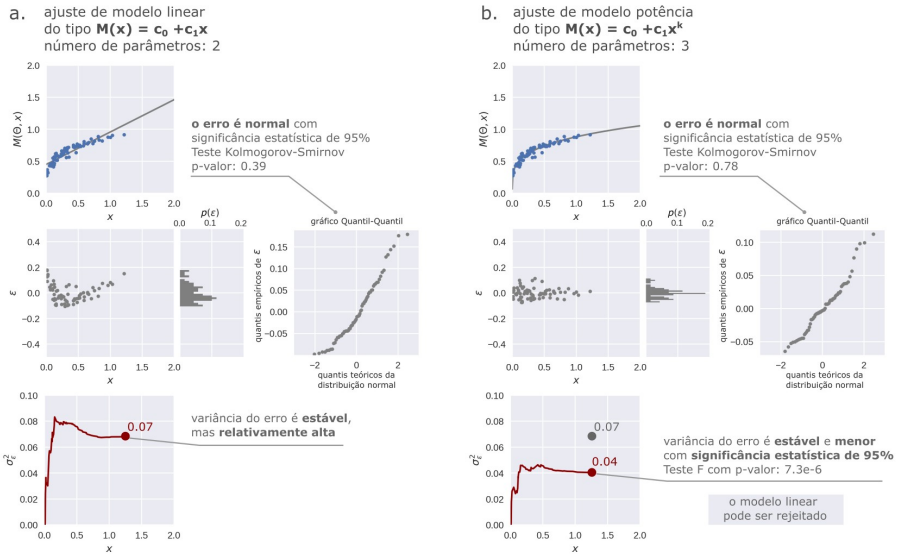

Figura 1.7 — Critérios de rejeição para seleção de modelos. **a.**— Ajuste de um modelo linear do tipo $M(x, \Theta) = c_1 x + c_0$. **b.**— Ajuste de um modelo potência do tipo $M(x, \Theta) = c_1 x^k + c_0$. Os dois modelos são ajustados para o mesmo conjunto de dados observados. Ambos os ajustes satisfazem as premissas de erro normal e variância estável (homoscedástica). Apenas pelo princípio da parcimônia (simplicidade), o modelo linear deveria ser preferido pois apresenta menos parâmetros. Mas o modelo potência apresenta variância do erro menor com significância estatística de 95%. Esse pode ser um critério de rejeição para o modelo linear.

A mesma lógica se aplica para órbitas circulares e elípticas: a teoria do círculo, sendo essa curva um caso específico de elipse, deve ser preterida antes da teoria da elipse não por sua estética, mas por sua facilidade de ser demonstrada falsa pelas evidências observadas.

O conceito de simplicidade de Popper faz sentido lógico, mas não responde exatamente como proceder diante de evidências observadas que apresentam ruído aleatório. Na prática, é impossível se obter dados perfeitamente aderentes a uma relação matemática fundamentada em algum princípio teórico, como uma função linear, quadrática, de potência, etc. Antes de prosseguir, aqui é importante diferenciar uma teoria de um **modelo estatístico**. As teorias estabelecem modelos matematicamente precisos sobre determinados fenômenos. Os modelos estatísticos, por outro lado, são um tipo de teoria muito específica, que definem precisamente *o padrão matemático de um conjunto de dados*, sem vínculos teóricos sobre os fenômenos subjacentes[18]. No caso das teorias, a questão em aberto na abordagem racionalista de Popper é quando que as anomalias nos dados devem ser levadas a sério a ponto de se rejeitar uma teoria simples para dar lugar a uma teoria mais complexa. Ou seja, o quanto que os dados devem se desviar do modelo proposto pela teoria para que ela seja considerada falseada pelas evidências? Essa pergunta inevitavelmente introduz uma decisão, que é a definição prévia de um **critério de rejeição**. A decisão sobre o critério de rejeição precisa ser *antes* da avaliação da teoria (*a priori*) porque se for *depois* nada impede que a teoria nunca seja rejeitada – basta estabelecer um critério sabidamente brando. O próprio Popper critica as teorias que, diante de evidências claramente falseadoras, usam de subterfúgios e explicações auxiliares *ad hoc* para tentar sobreviver. Esse dilema fica evidente no caso das premissas mencionadas na Seção 1.3 sobre o modelo estatístico do ruído aleatório: média

[18] Um exemplo intuitivo para essa diferença é considerar uma população, digamos, de mil triângulos com tamanhos aleatórios. Se olharmos os dados de perímetro e área, podemos facilmente criar um modelo estatístico entre essas duas variáveis: perímetros grandes em geral são acompanhados de áreas grandes. Mas isso não é uma lei teórica sobre os triângulos, pois alguns triângulos muito agudos apresentam grandes perímetros e área pequena. A teoria matemática obviamente é que a área de um triângulo é a sua base vezes altura dividido por dois – o perímetro está relacionado parcial e indiretamente.

nula, variância constante, independência no tempo e distribuição normal. Por exemplo, pode-se avaliar a premissa de normalidade do erro ε a partir do gráfico Quantil-Quantil ou com testes de hipótese, como o teste de Kolmogorov–Smirnov. No caso do gráfico Quantil-Quantil, a interpretação é puramente visual. Se o gráfico se desviar muito de uma linha reta, a premissa deve ser rejeitada. Já no caso do teste de hipótese, o nível de confiança para a hipótese nula é definido *a priori*. Se o nível de confiança desejado for definido em 95%, um p-valor menor ou igual que 0.05 quer dizer que a probabilidade da normalidade diante dos dados considerados é menor que 5%, e a premissa deve ser rejeitada. Existe justificativa lógica para o nível de 95%? Não existe. Outro exemplo, ilustrado na Figura 1.7, é quando todas as premissas sobre os resíduos são satisfeitas tanto por um modelo simples quanto por um modelo complexo, mas o modelo complexo é mais *acurado* que o modelo simples, ou seja, a dispersão do erro é *menor*. O quanto a dispersão deve ser menor para se rejeitar o modelo mais simples? De novo, é possível aplicar um teste de hipótese para variâncias iguais, o Teste-F, e se obter uma resposta para um nível de confiança definido previamente. Se as variâncias forem diferentes com significância estatística, deve-se rejeitar o modelo mais simples. De uma forma ou de outra, existe subjetividade envolvida na rejeição, pois são necessários critérios ou limiares definidos *a priori*.

1.5 Paradigmas

Na Filosofia da Ciência, existe uma diferença importante entre o **contexto da justificação** e o **contexto da descoberta**. O primeiro contexto trata do problema epistemológico de como justificar a verdade de uma teoria. O segundo contexto investiga o problema histórico e sociológico de como se dá o progresso na Ciência – se é que existe progresso. As diferentes correntes filosóficas citadas nas seções anteriores se enquadram no primeiro contexto, pois oferecem soluções para o problema epistemológico da justificação. De uma forma ou de outra, elas conferem um papel importante para as evidências empíricas. Para os empiristas Bayesianos, as evidências seriam utilizadas indutivamente para confirmar o grau de convicção em uma teoria a partir da matemática das probabilidades. Para os racionalistas críticos, as evidências seriam essenciais para falsear teorias a partir da lógica dedutiva, deixando as teorias em uma eterna condição provisória – elas seriam corroboradas mas nunca confirmadas. A *confirmação* e a *rejeição*, assim, formam uma dicotomia um tanto paradoxal, pois ambas fazem sentido na prática da Ciência, mas se contradizem. Esse paradoxo é eliminado pela perspectiva do contexto da descoberta. Em sua obra *A Estrutura das Revoluções Científicas*, Thomas Kuhn (1922-1996) traz uma contribuição substancial nesse sentido.

Como historiador, Kuhn adverte que a Ciência não existe pairando no nada: ao contrário, é constituída por uma *comunidade* de seres humanos que interagem ao longo da História, por sucessivas gerações, dentro de uma sociedade maior. A existência da **comunidade científica** implica que deve-se levar em conta não apenas a História da Ciência mas também a Sociologia da Ciência para entender o contexto da descoberta. Essa comunidade obviamente não é um bloco único, mas uma rede social de comunidades menores, de diferentes disciplinas e áreas do conhecimento. Nessa linha, Kuhn propõe que a dinâmica de uma dada comunidade científica produz um padrão histórico cíclico, estruturado por três fases encadeadas: o período da **ciência normal**, o período de **crise** e o período **revolucionário**. A confirmação e falsificação de teorias, portanto, predominam em diferentes etapas desse padrão histórico, sendo a confirmação um processo dominante no período da ciência normal e a rejeição uma característica essencial do período de crise. Mas o processo mais importante para mudança na Ciência, que ocorre durante o período revolucionário, é a **competição** entre teorias. Em suas palavras, "*a competição entre segmentos da comunidade científica é o único processo*

histórico que realmente resulta na rejeição de uma teoria anteriormente aceitável ou na adoção de outra". Esse processo é inevitavelmente intergeracional, pois novos membros da comunidade precisam ser reeducados a pensar sob uma nova visão de mundo. Para ilustrar esse ponto, Kuhn cita um trecho marcante da autobiografia do físico Max Planck (1858-1947): "*uma nova verdade científica não triunfa por convencer seus oponentes e fazê-los ver a luz, mas sim porque seus oponentes acabam eventualmente morrendo e uma nova geração cresce familiarizada com ela*".

Uma ideia chave para Kuhn é a de que uma comunidade científica compartilha um mesmo **paradigma**. Por paradigma, ele se refere a um conjunto de soluções exemplares para problemas de pesquisa, ou seja, um sistema de teorias, instrumentos e práticas auxiliares que resolvem muito bem certos problemas amplamente aceitos e são *promissores* para resolver problemas misteriosos e controversos com grande apelo competitivo. Esse apelo competitivo é importantíssimo, pois a atração de segmentos da comunidade em torno de um paradigma apresenta uma retroalimentação positiva: quanto mais segmentos adotam o paradigma, mais novos segmentos se convencem de que precisam adotá-lo também, sob a penalidade de ficar para trás. A comunidade científica no período normal, assim, opera tanto nas frentes teóricas quanto nas frentes aplicadas no sentido de reafirmar e articular o paradigma hegemônico. Não se faz pesquisa científica nesse período com o objetivo explícito de encontrar novidades inesperadas, e o sucesso de uma pesquisa normal *define-se justamente por não encontrar nenhuma surpresa*. Uma pesquisa bem sucedida geralmente confirma o que o paradigma vigente já prometia ao trazer um detalhamento mais refinado ou ao expandir o campo de aplicações (por exemplo, pela invenção de novas tecnologias). Como em um jogo de quebra-cabeça, na ciência normal se presume de antemão a imagem completa que as peças formam – o único desafio é fazer as peças se encaixarem. Aqui, surge a sensação de que a Ciência é um empreendimento *cumulativo*: cada novo membro introduzido na comunidade científica teria a humilde missão de assentar mais um pequeno tijolo em um grande "edifício do conhecimento humano". Na opinião de Kuhn, essa impressão de acumulação, além de equivocada no contexto maior, é reforçada pelo amplo uso de livros-texto na formação de novos pesquisadores. Esses livros didáticos funcionam como veículos da perpetuação do paradigma hegemônico porque, quando não são simplesmente escritos de forma anti-histórica, eles distorcem a História para que ela pareça um processo linear e inevitável na direção das teorias vigentes.

Kuhn argumenta, com diversos exemplos na História da Ciência, que as peças do quebra-cabeça estudado pela ciência normal eventualmente não se encaixam. Se por um lado o conhecimento se acumula durante o período normal, por outro também se acumulam **anomalias** empíricas e teóricas. Normalmente evitadas ou ignoradas, em dado momento essas anomalias passam a causar um mal-estar generalizado na comunidade científica, que entra então no período de crise. O exemplo de crise mais detalhado por Kuhn é a do geocentrismo, mas também ele oferece exemplos na química, na mecânica e no eletromagnetismo. Por esse ângulo, a História mostra que algumas crises se instalam lentamente, como na química, e que outras são súbitas, como a causada por Einstein na Física. Uma comunidade científica em crise apresenta diversos sintomas, tais como a discórdia, o descontentamento, debates filosóficos e, principalmente, a proliferação generalizada de teorias candidatas para explicar as anomalias.

A única saída para a crise é a revolução causada pela proposição de um paradigma que seja irresistível para a comunidade científica. Como já assinalado, o novo paradigma deve ser eficaz na solução de problemas já conhecidos e fazer promessas tentadoras para a solução dos problemas em aberto. As revoluções científicas, assim, são episódios em que o suposto edifício do conhecimento é demolido para que uma nova edificação seja erigida sobre uma nova fundação, com uma nova planta. Nesse período revolucionário, que geralmente dura uma geração, a comunidade científica migra em massa para o novo

paradigma. Novos livros-texto são então escritos e se instala um novo ciclo histórico de ciência normal. Um aspecto importante desse processo é que, para Kuhn, um paradigma novo é tão diferente do antigo que eles são *incomensuráveis*: a comunicação intelectual entre eles é extremamente precária, pois representam diferentes visões de mundo. Um exemplo típico de **incomensurabilidade** ocorre com o conceito de massa na física de Newton e na física de Einstein, pois enquanto que para um é uma propriedade constante, para outro é uma função da velocidade. Mesmo com o mesmo nome e o mesmo símbolo, são conceitos completamente diferentes. Com isso, Kuhn traz uma conclusão inquietante: a de que *não há progresso absoluto* na ciência na direção da verdade sobre a realidade, apenas *relativo* ao que estamos preocupados em explicar. Mais do que isso, com a sua tese, Kuhn aponta a profundidade da dinâmica social sobre a Ciência, que frequentemente é retratada como o mais racional dos empreendimentos humanos.

Como foi exposto, a tese de Thomas Kuhn sobre o contexto da descoberta elimina o paradoxo entre confirmação e falsificação, que são soluções contraditórias no contexto da justificação. Mas um olhar cauteloso capta que a abordagem de Kuhn é essencialmente empirista: ele busca *confirmar* as ideias de paradigmas e de revoluções científicas a partir de exemplos da História da Ciência, ou seja, a partir de *evidências empíricas*. Kuhn utiliza a inferência indutiva para justificar uma teoria sobre o contexto da descoberta. Pela perspectiva racionalista crítica, por mais bem corroborada que seja, um único contra-exemplo seria suficiente para falsear a teoria de Kuhn. O problema é que esse fato, paradoxalmente, *ressuscita a dicotomia entre confirmação e falsificação*. Para piorar, se a teoria de Kuhn é científica (ou seja, falseável), não seria ela *em si* um paradigma de como explicar o contexto da descoberta? Surge aqui um laço de auto-referência. Essa é uma típica situação aterrorizante de se estar andando em círculos que a Filosofia proporciona. Karl Popper, talvez por ser um filósofo e não um historiador, parece ter antevisto esses problemas e estabeleceu *a priori* que a teoria definitiva sobre o conhecimento não pode ser científica – falseável por evidências – mas apenas uma teoria baseada na Lógica.

1.6 Subdeterminação

O que vimos até o momento insere-se na corrente filosófica mais ampla chamada de **realismo científico**. Essa corrente essencialmente defende a tese de que o propósito da Ciência é providenciar teorias que são descrições verdadeiras da realidade [16]. Por exemplo, iniciamos este capítulo mencionando que Keith Beven classifica de *realismo pragmático* a filosofia da maioria dos usuários de modelos hidrológicos, que é o entendimento tácito de que os modelos asseguram uma descrição aproximada da realidade que pode ser melhorada com novas tecnologias. O realismo pragmático, para Beven, seria uma vertente do realismo científico. As origens do realismo científico podem ser identificadas nas ideias de René Descartes [17]. Aqui, é preciso estabelecer que o **realismo** em si consiste na concepção da Metafísica que admite a existência da realidade *objetiva*, ou seja, que o mundo não depende de ninguém para observá-lo. Nesse sentido, quando uma pessoa entra em uma sala e observa uma mesa, se admite que a mesa estava ali antes dela entrar. A mesa não se realizou instantaneamente no ato de observar. Objetos, como mesas, existem de forma independente dos sujeitos. Essa concepção se opõe ao **idealismo**, corrente que considera a realidade estritamente como um produto *subjetivo* da mente. Se concordamos com a existência de um suposto objeto, como uma mesa, é por que ela se realiza de forma similar em nossa mente, ou seja, *intersubjetivamente*. Descartes flerta com o idealismo quando ele questiona a sua própria existência em *O Discurso do Método*, em especial com a vertente do solipsismo – a ideia de que a mente de quem está lendo este texto é a única coisa que de fato existe. Descartes basicamente

aponta que, apesar de termos certeza absoluta sobre as ideias em nossa mente, é difícil garantir que elas correspondam à realidade externa. Nos termos dele, *verossimilhança não implica verdade*. Para tentar resolver esse problema, Descartes descreve o método que serviu de inspiração para a formação do método científico moderno, contribuindo para o debate em torno do problema da justificação que abordamos até agora. No final das contas, o problema da justificação está inerentemente contaminado pelo pressuposto de que a realidade objetiva existe, sendo o conceito de *verdade* precisamente a *correspondência* entre as teorias e a realidade.

A tese do realismo científico parece óbvia, mas não é tão simples assim de defendê-la. De fato, Bas van Fraassen [16] e Nancy Cartwright [18] fazem uma crítica profunda, propondo um ponto de vista radicalmente empirista denominado **instrumentalismo**[19] [19]. Ambos sustentam a tese de que o objetivo da Ciência é produzir teorias que apresentem *adequação empírica* – e nada além disso. Como adequação empírica não implica logicamente uma descrição verdadeira da realidade, a reivindicação do realismo científico é ambiciosa demais em termos epistemológicos. Esse ponto de vista não nega a existência da realidade (não é uma corrente idealista): o que se nega é a ambição de se obter uma descrição verdadeira sobre a realidade. As teorias e seus modelos seriam somente *instrumentos* úteis construídos por cientistas para explicar evidências empíricas. Um dos principais motivos para essa alegação é o **problema da subdeterminação**[20], que é a dificuldade de garantir que as evidências observadas determinem a verdade de uma teoria sem que existam teorias empiricamente equivalentes [20], [21]. A orientação de Popper, de se preferir sempre a teoria mais simples, só funciona bem para teorias completamente falseáveis pelas evidências empíricas. Isso não é o caso para a maior parte das teorias, que quase sempre postulam a existência *entidades inobserváveis* para explicar fenômenos que são diretamente observáveis. Por exemplo, na Física se evoca a existência de elétrons e campos eletromagnéticos (inobserváveis) para explicar os raios e relâmpagos de uma tempestade (observáveis). Isso complica tudo, pois não importa qual for a maneira de detectar as entidades inobserváveis, como os campos eletromagnéticos, as evidências indiretas sempre estarão contaminadas com uma *carga teórica embutida*[21] que estabelece a existências dessas entidades em primeiro lugar. Esse tipo de abordagem teórica envolve um tipo de raciocínio não-dedutivo, chamado de**inferência à melhor explicação**[22], ou abdução. Por não ser dedutivo, esse raciocínio não garante a verdade da sentença consequente e também está sujeito ao problema da indução postulado por Hume. Assim, uma teoria que instancia entidades inobserváveis paga o preço de ser subdeterminada pelas evidências empíricas observáveis.

Uma das principais defesas do realismo científico consiste em evocar o sucesso da Ciência como evidência de que as teorias científicas, mesmo instanciando entidades inobserváveis, progridem para descrever a realidade de forma cada vez mais verdadeira [22]. Pela perspectiva racionalista crítica, ainda que a verdade última sobre a realidade esteja permanentemente protegida, a rejeição de teorias oportuniza a seleção incremental do conjunto de ideias potencialmente verdadeiras. De fato, é inegável que as predições teóricas e as aplicações tecnológicas que a Ciência produziu nos últimos séculos são impressionantes e não têm precedentes históricos. Diante de todo esse sucesso, até soa um tanto absurdo considerar que a Ciência moderna não descreve a realidade. Apesar da inferência à melhor explicação não garantir uma implicação lógica, como corretamente assinalam os instrumentalistas, os defensores do realismo científico argumentam que

[19] Instrumentalismo é uma denominação abrangente e neutra. Por exemplo, van Fraassen autodenomina sua tese de *empirismo construtivista*. Os realistas, por sua vez, classificam o instrumentalismo de *anti-realismo*.

[20] Tradução livre do termo em inglês *underdetermination*.

[21] Tradução livre do conceito de *theory-ladenness* em inglês.

[22] Tradução livre do termo em inglês *inference to the best explanation*.

seria *um milagre* extremamente improvável as teorias atuais estarem obtendo bons resultados por motivos errados. Entretanto, Donald Hoffman traz a possibilidade de que as teorias científicas descrevam com notável adequação empírica o comportamento de uma *interface cognitiva* [23]. Ele sustenta que sistemas cognitivos, quando submetidos à seleção natural, são pressionados a operar através da **heurística**. Ou seja, aqueles sistemas que compactam as informações necessárias para tomar decisões úteis ganham vantagem competitiva. A evolução desses sistemas resulta em uma interface perceptual otimizada para a sobrevivência e reprodução, mas cuja probabilidade de ser equivalente à realidade é *precisamente zero*. Como analogia, considere a interface gráfica de um computador. Nesse caso, podemos facilmente observar o comportamento de botões e ícones para identificar padrões sem saber nada sobre os mecanismos eletrônicos subjacentes. As informações da interface gráfica não dizem absolutamente nada sobre o *hardware*. Para Hoffman, a verdade sobre realidade pode simplesmente não ter nada a ver com espaço, tempo, energia, matéria, etc – nos termos de Kant, essas seriam as categorias transcendentais que usamos para compactar e integrar informações perceptuais [23].

O problema da subdeterminação tem implicações diretas e relevantes para usuários de modelos ambientais, incluindo modelos hidrológicos. Nesse contexto, Naomi Oreskes aponta que a subdeterminação ocorre porque diversos processos representados pelos modelos não são observáveis *na prática*, ou seja, as informações sobre o sistema modelado são *incompletas* tanto no tempo quanto no espaço [25]. Essa versão mais branda da subdeterminação também é denominada de **problema da equifinalidade**[26]. Por exemplo, considere o escoamento subterrâneo que ocorre em bacias hidrográficas. É evidente que esse processo existe: uma expedição de campo torna isso claro ao se observar diretamente as nascentes dos riachos, os locais onde a água subterrânea aflora para a superfície. Inclusive, piezômetros podem ser instalados para se monitorar o nível do lençol freático, o que traz mais evidências diretas sobre esse processo. Porém, a extensão e a dinâmica completa desses fluxos subterrâneos é impossível de se monitorar na prática, sendo observável apenas pontualmente. Oreskes argumenta que a parcialidade das informações torna os sistemas naturais modelados *logicamente abertos*. Ao contrário de sistemas logicamente fechados, como algoritmos e equações matemáticas, ela aponta que é impossível verificar ou validar um sistema logicamente aberto diante de *circunstâncias extenuantes* que frequentemente garantem explicações empiricamente equivalentes, ou *equifinais*. Isso é intuitivo, quando não temos informações completas sobre algum evento que observamos, é natural o surgimento de explicações rivais e igualmente válidas. Aliás, é justamente por esse motivo que experimentos científicos são projetados de forma a se reduzir a abertura lógica do sistema avaliado, ou seja, reduzir a influência das circunstâncias extenuantes. Assim, os modelos de sistemas naturais se apresentam como uma **hipótese principal** que precisa da ajuda de **hipóteses auxiliares**, tais como parâmetros, os dados de entrada, as escalas adotadas e, principalmente, as premissas teóricas subjacentes. Assim, surge um paradoxo: é justamente em razão da ausência de informações que se busca a aplicação de modelos em primeiro lugar. Se as informações já estivessem completamente disponíveis, dificilmente um modelo seria relevante para a tomada de decisão. Mas sem as informações comple-

[23] Donald Hoffman avança, subvertendo o paradigma do fisicalismo material que predomina na Ciência ao propor que a realidade não é constituída fundamentalmente de partículas subatômicas, mas sim de uma rede infinita de interações entre agentes conscientes [24]. As interações desses agentes produzem interfaces cognitivas que eventualmente instanciam laços de auto-referência, ou seja, realizam um *Self*, um "Eu". Essa hipótese explica ao mesmo tempo tanto por que experiências subjetivas existem (note que elas não são previstas dentro do fisicalismo material) quanto por que o realismo definitivamente não se sustenta em escalas quânticas (as propriedades supostamente físicas são realizadas instantaneamente no ato de observar). Apesar rejeitar o fisicalismo, a hipótese de Hoffman é científica, pois é falseável no sentido de que seu desenvolvimento matemático deve, obrigatoriamente, reprojetar as leis da Física como as conhecemos através da interface.

tas, um modelo torna-se subdeterminado pelas evidências disponíveis – o problema da subdeterminação na aplicação de modelos é inexorável.

Para Keith Beven, o reconhecimento do problema da subdeterminação na modelagem hidrológica traz consequências radicais para a confirmação de modelos diante das evidências observadas, que é a necessidade de se avaliar o **erro total** associado a um dado modelo hidrológico [27]. Por essa perspectiva, a Equação (1.3) estaria incompleta, pois ali o erro ε representa apenas o ruído aleatório relacionado às evidências observadas. É necessário incluir não somente a **incerteza estatística**, resultante exclusivamente do ruído amostral, mas também a **incerteza epistêmica**, que decorre das hipóteses auxiliares necessárias para endereçar o problema da subdeterminação [28]. Sendo assim, a **equação do erro total** para modelos hidrológicos apresenta a seguinte forma:

$$O(x,t) + \varepsilon_O(x,t) + \varepsilon_\Delta(\Delta x, \Delta t, x, t) = M(\Theta, \Upsilon, \varepsilon_\Upsilon, x, t) + \varepsilon_M(\Theta, \Upsilon, \varepsilon_\Upsilon, x, t) + \varepsilon_r \quad (1.5)$$

Em que $O(x,t)$ é a observação obtida na variável independente x[24] e no tempo t; $\varepsilon_O(x,t)$ é o **erro de medição** da observação; $\varepsilon_\Delta(\Delta x, \Delta t, x, t)$ é o **erro de comensurabilidade** na escala de modelagem Δx e Δt; $M(\Theta, \Upsilon, \varepsilon_\Upsilon, x, t)$ é a predição do modelo em x, t a partir do vetor de parâmetros Θ, do vetor de dados de entrada Υ e do **erro dos dados de entrada** ε_Υ; $\varepsilon_M(\Theta, \Upsilon, \varepsilon_\Upsilon, x, t)$ é o **erro estrutural do modelo**, e; ε_r é o **erro aleatório** remanescente. O erro de comensurabilidade ε_Δ resulta da conversão entre escalas, representando a incerteza epistêmica da diferença de significado entre uma observação obtida pontualmente em x, t e a variável correspondente modelada em $\Delta x, \Delta t$. Por exemplo, enquanto a vazão observada de um rio é instantânea e referente a uma seção específica do canal, a vazão modelada integra algum passo de tempo e se refere a uma extensão espacial discreta. O erro de medição ε_O e o erro de comensurabilidade ε_Δ são mantidos do lado esquerdo da Equação (1.5) para denotar que juntos eles compõe o **erro observacional efetivo** Já o erro dos dados de entrada ε_Υ origina-se do agrupamento das incertezas tanto das condições de contorno (como os mapas da topografia, solos, vegetação, etc), quanto das variáveis forçantes do modelo (como chuva, temperatura, velocidade do vento, etc). Nesse caso, a incerteza geralmente é estatística, de maneira que amostras representativas tendem a reduzir seu impacto. Ela pode, contudo, também assumir uma natureza epistêmica quando os dados de entradas correspondem a **cenários**, fato que agrega uma carga conceitual. Por fim, o erro estrutural do modelo ε_M resulta da incerteza epistêmica da configuração teórica e numérica do modelo hidrológico. Essa componente é fortemente influenciada pelas premissas teóricas previamente definidas sobre o sistema e seus processos hidrológicos.

Com a Equação (1.5), Keith Beven operacionaliza um paradigma instrumentalista para a modelagem hidrológica que, para além da confirmação, *admite a rejeição de modelos*. Essa abordagem segue as recomendações discutidas por Albert Tarantola, de considerar tanto a confirmação empirista de Bayes quanto a rejeição racionalista de Popper para uma abordagem filosoficamente explícita de modelagem ambiental [29]. Nessa linha, a crítica sobre o paradigma hegemônico de modelagem, dominado pelo realismo pragmático, é que a confirmação de modelos ocorre sob o preço de se subestimar as incertezas epistêmicas, mascarando elas em um erro aleatório que é minimizado pelo ajuste de técnicas de otimização, como na Equação (1.3). Através do **processo de calibração** convencional[25], chega-se na conclusão (equivocada) de que o modelo ajustado que foi identificado consiste na única representação empiricamente adequada. Por outro lado, a nova abordagem instrumentalista, nas palavras de Beven, "*consiste em aceitar*

[24] Em modelos hidrológicos a variável independente geralmente é o espaço bidimensional, ou seja, deve-se substituir x por x, y.

[25] Também denominado de *problema invertido*

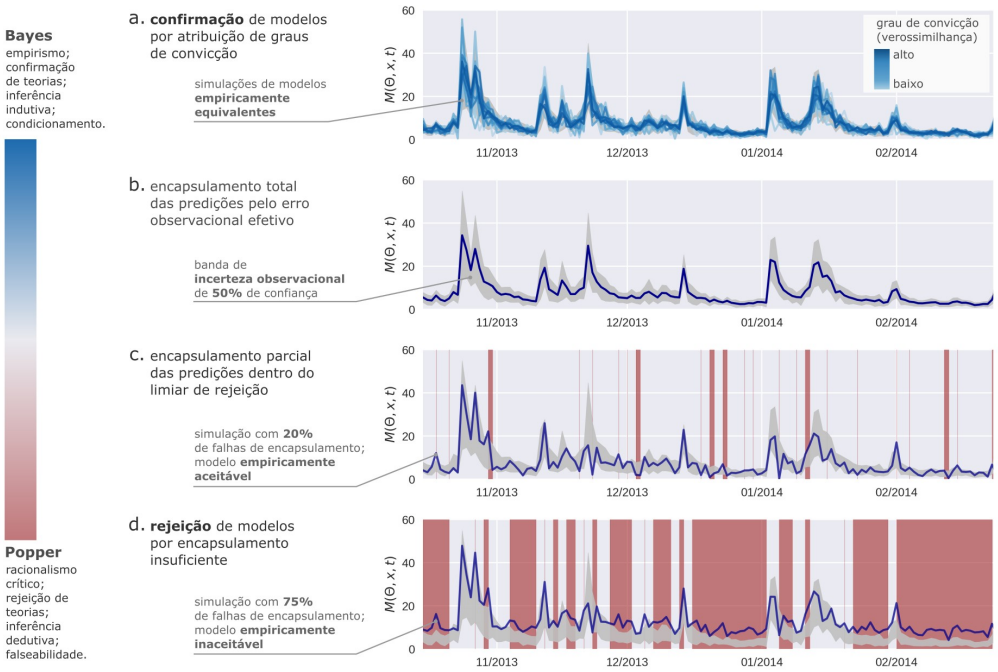

Figura 1.8 — Abordagem instrumentalista para a modelagem hidrológica. Nessa abordagem tanto a confirmação de Bayes quanto a rejeição de Popper são empregadas sob o reconhecimento do problema da subdeterminação (equifinalidade). **a.**— Confirmação de modelos pelo condicionamento bayesiano, em que graus de confirmação (medidas de verossimilhança informais) são atribuídos para modelos empiricamente equivalentes. No caso, todos os modelos foram encapsulados pela banda de incerteza observacional dentro do limiar de rejeição pré-estabelecido. **b.**— Encapsulamento total (sem falhas) de uma simulação (série temporal) pelo erro observacional efetivo das evidências empíricas. No caso ilustrado a banda de incerteza apresenta nível de confiança de 50%. Uma banda mais ou menos abrangente deve ser definida *a priori*. **c.**— Encapsulamento parcial (com 20% de falhas) de uma simulação pelo erro observacional efetivo. Como a banda é de 50% de confiança, as falhas estão dentro do limiar de rejeição e o modelo pode ser considerado empiricamente aceitável. **d.**— Rejeição de modelos por encapsulamento insuficiente (75% de falhas). Nesse caso as falhas superam o nível de 50% de confiança e o modelo deve considerado empiricamente inaceitável.

que é muito implausível que as estruturas de nossos modelos atuais sejam descrições realisticamente verdadeiras dos sistemas ambientais de interesse, de maneira que talvez existam muitos outras configurações que produzam predições aceitavelmente consistentes com quaisquer dados observados disponíveis. Isso consiste em tratar o problema da identificabilidade como um problema de equifinalidade de estruturas e parâmetros de modelos em reproduzir o comportamento conhecido do sistema"[26] [1]. É importante assinalar que essa nova abordagem não abandona o processo de confirmação pelo método de condicionamento Bayesiano da distribuição posterior dos parâmetros Θ. Ainda que a equação do erro total torne impossível um tratamento formal da verossimilhança $P(O|M)$, permanece possível a atribuição de diferentes graus de convicção, ou pesos, para os **modelos empiricamente equivalentes** por medidas de verossimilhança informais $\mathcal{L}(O|M)$. A novidade da abordagem consiste em estabelecer que um **modelo empiricamente aceitável**[27] ocorre quando o seu erro estrutural ε_M for menor que o seu erro observacional efetivo $\varepsilon_O + \varepsilon_\Delta$. Do contrário, o modelo deve ser rejeitado. Isso implica que as predições de um modelo qualquer devem ser *encapsuladas*[28] por um

[26] Tradução livre de: "*There is, however, another approach. That is to accept that it is very unlikely that our current model structures are truly realistic descriptions of the enviromental systems of interest so that there may indeed be many different models that can be shown to provide predictions that are acceptably consistent with whatever observed data are available. That is to treat the problem of identifiability as one of equifinality of model structures and parameter sets in reproducing the known behaviour of the system*".

[27] Keith Beven se refere a modelos empiricamente aceitáveis por *behavioural models*.

[28] Tradução livre do termo *bracketing* em inglês.

intervalo de confiança definido *a priori* como um critério de rejeição. Ou seja, para um nível de confiança de $\alpha\%$, a **inequação de encapsulamento**:

$$O_{100-\alpha\%}(x,t) < M(\Theta, \Upsilon, \varepsilon_\Upsilon, x, t) < O_{\alpha\%}(x,t) \quad \forall \quad x,t \tag{1.6}$$

deve ser válida com uma frequência de pelo menos $\alpha\%$; em que $O_{100-\alpha\%}$ e $O_{100-\alpha\%}$ são os limiares inferiores e superiores do intervalo de confiança do erro observacional efetivo em cada ponto amostral x, t. Essa abordagem tem exatamente a mesma estrutura dos testes de hipótese estatísticos: 1) se define previamente um critério de rejeição por um nível de confiança $\alpha\%$; 2) se calcula uma estatística de teste, no caso a taxa de encapsulamento da simulação, e; 3) se avalia o p-valor do teste, que no caso é a taxa de falhas de encapsulamento. Se o p-valor for maior que o nível de confiança, deve-se rejeitar o modelo. Por outro lado, todos os modelos que passarem pelo teste de encapsulamento mínimo são tidos como empiricamente equivalentes e podem ser confirmados com base em medidas de verossimilhança. A Figura 1.8 ilustra a abordagem para o encapsulamento de uma série temporal de uma variável hidrológica qualquer, mas que geralmente é a vazão em uma seção de rio. Nota-se que pré-definição do nível de confiança implica em bandas de incerteza observacional mais ou menos abrangentes. Esse fato introduz o seguinte dilema: quando se deseja muita certeza sobre as predições, a banda observacional pode ser muito larga, resultando em diversas simulações empiricamente aceitáveis e pouca precisão do erro estrutural. Isso cria a necessidade de se obter mais evidências, de forma que as observações em si apresentem bandas estreitas para níveis altos de confiança. Outro aspecto diferente do paradigma hegemônico, que opera unicamente pela confirmação, nada impede a eventual *rejeição de todos os modelos testados* pela inequação de encapsulamento. Se for o caso, Beven salienta, surge uma oportunidade valiosa para transformar a modelagem em um processo de aprendizado, que obriga os usuários a revisar detalhadamente tanto as hipóteses auxiliares quanto a hipótese principal, ou seja, as próprias premissas teóricas adotadas na concepção dos processos hidrológicos modelados. No limite, a rejeição total impõe a necessidade de novas teorias e explicações. Sem isso, a comunidade científica desse campo estará eternamente presa aos mesmos paradigmas. ■

1.7 Resumo do capítulo

Este capítulo buscou estabelecer os fundamentos de uma filosofia instrumentalista para a aplicação de modelos hidrológicos. Essa filosofia entende que a tomada de decisão baseada em evidências deve ser auxiliada por informações sobre a incerteza empírica inerente ao uso de modelos. Nesse sentido, é preciso uma atitude crítica diante do que os modelos hidrológicos literalmente são (voltagens em circuitos eletrônicos) e o que os usuários de modelos hidrológicos imaginam (processos hidrológicos em bacias hidrográficas). As principais conclusões são:

- **O problema da justificação**. Existe uma dificuldade de se justificar a verdade de teorias, de se estabelecer explicações definitivas sobre os eventos e fenômenos. Por um lado, os racionalistas apelam para o uso de inferência dedutiva, que garante a verdade de enunciados desde que suas premissas sejam verdadeiras. Por outro, os empiristas preferem usar a inferência indutiva, que faz uso de evidências empíricas para generalizar padrões observados.

- **Confirmação indutiva de hipóteses**. A epistemologia bayesiana descreve o processo de condicionamento empírico para confirmar hipóteses. Ao se reconhecer a existência de ruído aleatório nas observações empíricas, a verdade de uma hipótese deve ser descrita como um grau de convicção, ou probabilidade. Nesse processo, a distribuição de probabilidade de hipóteses é incrementalmente ajustada a partir da aplicação do teorema de Bayes.

- **Rejeição dedutiva de teorias**. Karl Popper, ao analisar a Lógica da pesquisa científica, defende que a única forma segura de se adquirir conhecimento é pela refutação dedutiva. Nesse sentido, o papel das evidências empíricas consiste em testar uma hipótese a partir de contra-exemplos que provam sua falsidade. Por esse motivo, Popper alega que as teorias científicas devem ser teorias falseáveis, que permitem sua própria rejeição.

- **Paradigmas e o contexto da descoberta**. Thomas Kuhn, ao explorar a História da Ciência, elimina a aparente contradição entre confirmação e rejeição de teorias. Ele sustenta que a dinâmica da comunidade científica desempenha um papel profundo na produção do conhecimento, especialmente no advento de paradigmas. Para ele, a confirmação ocorre em períodos de ciência normal, enquanto que a rejeição predomina em períodos de crise. Os períodos de crise só acabam quando a competição de novas ideias dá lugar a um novo paradigma.

- **O problema da subdeterminação**. O realismo científico é profundamente questionado por Bas van Frassen e Nancy Cartwright. Eles estabelecem uma perspectiva instrumentalista, em que o objetivo da Ciência é unicamente produzir teorias empiricamente adequadas. Isso decorre principalmente da instância de entidades inobserváveis, fato que torna as teorias subdeterminadas pelas evidências. Uma versão disso ocorre na modelagem hidrológica pelo fato de muitos processos modelados não serem observáveis na prática – o denominado problema da equifinalidade. Nessa linha, Keith Beven propõe um paradigma instrumentalista para a aplicação de modelos, que permite a rejeição de modelos a partir do teste de encapsulamento das predições pela incerteza observacional. Os modelos que passam no teste são tidos como empiricamente aceitáveis e equivalentes.

Glossário

bayesianismo objetivo Corrente da epistemologia bayesiana que defende que a distribuição anterior deve ser definida de forma a se observar o princípio da indiferença. 10

bayesianismo subjetivo Corrente da epistemologia bayesiana que defende que qualquer distribuição anterior é válida, desde que não se viole o princípio do probabilismo. 10

ciência normal Conceito articulado por Thomas Kuhn que se refere ao período histórico em que uma dada comunidade científica compartilha o mesmo paradigma. A ciência normal tender a acabar em uma crise que é seguida da revolução imposta pelo advento de um novo paradigma. 20

comunidade científica As pessoas que exercem a Ciência na prática em um dado período da História. Pode ser a totalidade de cientistas ou um subconjunto específico de alguma área do conhecimento. Thomas Kuhn argumenta que durante certos períodos históricos a comunidade científica é caracterizada por compartilhar um paradigma. 20

condicionamento [sinônimo de condicionalização]Aplicação do Teorema de Bayes sobre uma hipótese, de forma a se atualizar o seu grau de convicção. Pode ser realizado em etapas sucessivas, à medida que novas evidências são obtidas. 9

contexto da descoberta Perspectiva da Filosofia da Ciência que se trata do problema de entender a mudança de teorias na História. 20

contexto da justificação Perspectiva da Filosofia da Ciência que se trata do problema da justificação da verdade de teorias. 20

curvas-chave Relação funcional entre o nível e a vazão de um rio ou canal em uma determinada seção. Em geral, a seguinte função potência é utilizada: $Q = a(h - h_0)^b$, em que Q é a vazão; h é o nível, e; a, b e h_0 são os parâmetros ajustados pelos dados observados. 11

empirismo Corrente filosófica que defende a que a origem de todo conhecimento é a experiência empírica, ou seja, observações sobre o mundo externo à mente. Essa corrente faz oposição ao racionalismo. 5

equação do erro total Equação que inclui todas as fontes de erros em um modelo, tanto estatísticas quanto epistêmicas. 25

erro de comensurabilidade Incerteza epistêmica decorrente da diferença entre escalas no tempo e no espaço dos processos observados e os processos modelados. 25

erro de medição Incerteza estatística decorrente da medição de evidências empíricas. 25

erro dos dados de entrada Incerteza estatística e epistêmica associada aos dados utilizados para a configuração do modelo. Por exemplo: dados de chuva apresentam incerteza estatística da medição e a incerteza epistêmica da sua interpolação espacial. 25

erro estrutural do modelo Incerteza epistêmica associada aos conceitos teóricos e aos procedimentos computacionais empregados em um dado modelo. 25

erro observacional efetivo Superposição do erro de medição e o erro de comensurabilidade, representado a incerteza que o modelo deve ser submetido para se avaliar a sua adequação empírica. 25

espaço de possibilidades Conjunto de possibilidades gerado entre hipóteses e evidências na epistemologia bayesiana. Para se aplicar a matemática das probabilidades sobre esse conjunto, é preciso que as possibilidades sejam *mutuamente excludentes* (não podem ser verdadeiras ao mesmo tempo) e *conjuntamente exaustivas* (pelo menos uma delas é verdadeira). 7

falseabilidade Capacidade de uma teoria ser demonstrada falsa a partir da experiência empírica (observações e experimentos). Uma teoria falseável não é *necessariamente* falsa, mas *pode* ser considerada falsa de evidências empíricas. No racionalismo crítico, essa capacidade é o critério de demarcação para uma teoria ser considerada científica. 17

grau de convicção Conceito central no epistemologia bayesiana que decorre da ideia de que o conhecimento não é uma questão de tudo ou nada, mas que apresenta sutilezas entre o verdadeiro e o falso. Esse conceito pode ser considerado uma probabilidade sob certas circunstâncias. 7

heurística Conjunto de técnicas de solução de problemas que não garantem uma solução ótima ou racional, mas são suficientes para atingir os propósitos práticos da tomada de decisão. O principal exemplo é a solução de problemas por tentativa e erro. 24

hipóteses auxiliares Conjunto de hipóteses necessárias para além da hipótese principal de um modelo. 24

hipótese Enunciado universal em estágio probatório para ser alçado ao *status* de teoria a partir da sua confirmação. 6

idealismo Concepção metafísica que faz oposição ao realismo. Nessa perspectiva, que pode ter interpretações ontológicas ou epistemológicas, a realidade é entendida como um produto subjetivo da mente. 22

incerteza empírica Componente científico das incertezas no processo de tomada de decisão em políticas baseadas em evidências. Consiste no conjunto de incertezas epistêmicas e estatísticas sobre o estado do mundo. Outras componentes não-empíricas são: incerteza ética e incerteza política. 4

incerteza epistêmica Conceito geral que se refere às diversas incertezas não-estatísticas existentes no processo de modelagem. Ao contrário da incerteza estatística, que se refere às informações disponíveis, a incerteza epistêmica está associada às informações indisponíveis. 25

incerteza estatística Incerteza decorrente do ruído aleatório existente nos dados observados. Esse tipo de incerteza apresenta características estatísticas estacionárias que podem ou não ser estruturadas com viés, heteroscedasticidade e auto-correlação.

De uma forma ou de outra, essa incerteza pode ser modelada por distribuições de probabilidade. 7, 25

incomensurabilidade Conceito articulado por Thomas Kuhn que se refere ao problema de comunicação intelectual entre diferentes paradigmas. Dois paradigmas são fundamentalmente diferentes de maneira que é precária a comparação entre seus conceitos (mesmo que apresentem o mesmo nome e mesmo símbolo matemático). 22

inequação de encapsulamento Inequação utilizada para se testar se um modelo é empiricamente aceitável. Os resultados simulados do modelos devem ser encapsulados pelas bandas de incerteza das observações (erro observacional total) com um nível de confiança pré-definido (critério de rejeição). 27

inferência dedutiva Operação da Lógica que estabelece a verdade de um dado enunciado a partir de premissas antecedentes. A verdade do enunciado consequente só é garantida desde que suas premissas antecedentes sejam também verdadeiras. 5

inferência indutiva Raciocínio baseado em uma generalização ou extrapolação que estabelece um enunciado universal a partir de enunciados singulares. A verdade do enunciado universal não é garantida, mas apresenta graus de probabilidade. 5

inferência à melhor explicação [sinônimo de abdução] Raciocínio não-dedutivo que busca definir a hipótese que melhor explica as evidências empíricas.. 23

instrumentalismo Corrente da Filosofia da Ciência radicalmente empirista que faz oposição ao realismo científico. Essa corrente defende que o objetivo da Ciência é produzir teorias que sejam adequadas empiricamente e apenas isso. Seu argumento é que adequação empírica não implica uma descrição verdadeira da realidade. 4, 23

modelo empiricamente aceitável Modelo que apresenta resultados simulados que satisfazem as observações empíricas com um nível de confiança pré-estabelecido. 26

modelo estatístico Um modelo estatístico é uma teoria específica sobre o comportamento matemático dos dados, sem vínculos teóricos sobre os fenômenos subjacentes. 19

modelos empiricamente equivalentes Modelos diferentes mas que apresentam resultados simulados que não apresentam desvios significativos diante do erro observacional total. Nesse caso, não existe razão empírica para favorecer um modelo de outro, pelo menos em relação à hipótese principal dos modelos. 26

modelo Lorem ipsum dolor sit amet, consectetur adipiscing elit. Cras erat elit, consequat vel erat ac, tincidunt pulvinar lacus. Pellentesque vitae consectetur quam. Interdum et malesuada fames ac ante ipsum primis in faucibus. 11

paradigma Conceito articulado por Thomas Kuhn que se refere ao conjunto de soluções exemplares para problemas de pesquisa, ou seja, um sistema de teorias, instrumentos e práticas auxiliares que resolvem muito bem certos problemas amplamente aceitos e são promissores para resolver problemas controversos em aberto com grande apelo competitivo. 21

políticas baseadas em evidências Conceito de políticas públicas que buscam suporte total ou parcial em evidência objetivas para guiar a tomada de decisão e alocação de recursos. 4

positivismo lógico Movimento filosófico empirista do início do século XX, também chamado de empirismo lógico. 7

princípio da condicionalização Princípio utilizado na epistemologia bayesiana para atualizar os graus de convicção em hipóteses a partir das evidências. Para manter a concordância com o princípio do probabilismo, a condicionalização implica em zerar, escalonar e normalizar os valores das probabilidades atualizadas. 9

princípio da indiferença Princípio adotado pela corrente objetiva do bayesianismo que estabelece que o grau de convição em duas ou mais hipóteses deve ser igual desde que não existam razões para o contrário. Ou seja, diante da ignorância completa, a distribuição anterior deve ser uniforme. 10

princípio da uniformidade Suposição de que as mesmas regularidades naturais observadas empiricamente no passado serão as mesmas a serem observadas no futuro. Ou seja, de que a natureza é previsível a partir de seu passado, que nenhuma mudança arbitrária ocorrerá em suas leis (por exemplo, a Terra simplesmente parar de girar). 6

princípio do probabilismo Princípio utilizado na epistemologia bayesiana para tratar os graus de convicção como probabilidaes. Ele apresenta três axiomas: a não-negatividade; a normalização, e; a aditividade. 8

probabilidade anterior Probabilidade que de a hipótese H é verdadeira antes de considerar a probabilidade de que a evidência favorável E é verdadeira. Denotada como $P(H)$. 8

probabilidade posterior Probabilidade que de a hipótese H é verdadeira depois de considerar a probabilidade de que a evidência favorável E é verdadeira. Denotada como $P(H|E)$. 8

problema da demarcação Dificuldade de estabelecer a diferença entre uma teoria científica de uma teoria apenas metafísica, que se baseia apenas em abstrações puras. 17

problema da equifinalidade Notação de Keith Beven para a versão branda do problema da subdeterminação no caso de modelos numéricos ambientais. A subdeterminação dos modelos ocorre porque as informações sobre os processos modelados são incompletas, fato que garante a existência de estruturas de modelos que são empiricamente equivalentes, ou equifinais. 24

problema da indução Também chamado de **problema da indução de Hume**. Argumento circular inválido que surge da justificação do conhecimento indutivo pelo princípio da uniformidade, pois evoca o próprio conhecimento indutivo para se sustentar. 6

problema da justificação Dificuldade de se estabelecer a verdade de um determinado conhecimento ou teoria. 5

problema da regressão infinita Dificuldade de se estabelecer a origem última do conhecimento lógico ou racional, tendo em vista que todas as premissas precisam ser deduzidas de outras premissas mais primordiais, fato que leva a um encadeamento infinito (ou circular) de premissas. 6

problema da subdeterminação Dificuldade de garantir que as evidências observadas determinem a verdade de uma teoria sem que existam outras teorias empiricamente equivalentes. 23

problema dos anteriores Dificuldade de se justificar a definição incial dos grau de convição em uma hipótese antes de obter qualquer evidência. Na epistemologia bayesiana, soluções para esse problema são propostas principalmente por duas abordagens: a objetiva e a subjetiva. 10

processo de calibração Procedimento de ajuste dos parâmetros de um modelo para se aumentar o seu grau de confirmação diante das evidências empíricas. 25

racionalismo crítico Corrente filosófica racionalista proposta por Karl Popper que estabelece a falseabilidade como critério de demarcação de teorias científicas. Nessa visão, o poder das evidências empíricas está em justificar, por lógica dedutiva, a falsidade de teorias (nunca a verdade). Por exemplo, basta apenas um único cisne negro para que a teoria de que todos os cisnes são brancos ser considerada falsa. Enquanto não são refutadas, as teorias são apenas corroboradas pelas evidências. 17

racionalismo Corrente filosófica que defende a superioridade da lógica dedutiva, intuitiva e inata ao conhecimento humano, para a justificativa da verdade de teorias. Essa corrente faz oposição ao empirismo. 5

realismo científico Corrente da Filosofia da Ciência que defende a tese de que o propósito da Ciência é providenciar teorias que são descrições verdadeiras da realidade. 22

realismo pragmático Denominação proposta por Keith Beven para o realismo implícito corrente entre os usuários de modelos ambientais. Nessa filosofia, se aceita que os modelos providenciam representações aproximadas da realidade e que podem melhorar à medida que novas tecnologias tornam-se disponíveis. 4

realismo Concepção metafísica que admite a existência da realidade objetiva, ou seja, que a realidade não depende de ninguém para observá-la. 22

simulações de Monte Carlo Método numérico em que são realizadas inúmeras reamostragens estatisticamente equivalentes para se estimar o comportamento final de um modelo envolvendo variáveis aleatórias (ou seja, quando $n \to \infty$). O nome Monte Carlo se refere a um cassino de Mônaco, em alusão ao fato de se realizar inúmeras jogadas para se fazer uma análise estatística robusta. 12

teorema de Bayes Formulação matemática para a determinação da propabilidade posterior: $P(H|E) = P(H) \cdot P(E|H)/P(E)$, que siginifica Posterior = Anterior $\times$ Verossimilhança $\div$ Evidência. 8

teorema do limite central Teorema que estabelece o fato matemático que a média amostral de qualquer população apresenta distribuição normal. Não importa qual a distribuição da população (uniforme, normal, etc), a média obtida de amostras será normalmente distribuída. Esse fato acontece porque a média é uma soma, e em somas de números aleatórios os valores baixos amostrados tendem a compensar os valores altos, resultando em um padrão de sino invertido parecido com a distribuição normal. 12

teoria Na epistemologia, consiste em um enunciado universal (ou sistema de enunciados) que estabelece definitivamente a verdade de um fenômeno. 5

verossimilhança Probabilidade de que a evidência E é verdadeira depois de considerar a probabilidade da hipótese H ser verdadeira. Denotada por $P(E|H)$. 8

Bibliografia

[1] K. Beven, *Environmental Modelling: An Uncertain Future? An introduction to techniques for uncertainty estimation in environmental prediction*. Routledge, 2009, p. 329, ISBN: 0-203-93248-X.

[2] M. Ongaro e M. Andreoletti, «Non-Empirical Uncertainties in Evidence-Based Decision Making,» *Perspectives on Science*, vol. 30, pp. 305–320, 2 abr. de 2022, -Evidence-based policy¡br/¿- Scientific advice is limited to empirical uncertainty, ISSN: 15309274. DOI: 10.1162/posc_a_00416.

[3] P. Markie e M. Folescu, «Rationalism vs. Empiricism,» em *The Stanford Encyclopedia of Philosophy*, E. N. Zalta e U. Nodelman, eds., Spring 2023, Metaphysics Research Lab, Stanford University, 2023.

[4] R. Descartes, P. Neves e D. Rosenfield, *Discurso do método:* (Coleção L&PM pocket). L&PM, 2008, ISBN: 9788525410979.

[5] W. Uzgalis, «John Locke,» em *The Stanford Encyclopedia of Philosophy*, E. N. Zalta e U. Nodelman, eds., Fall 2022, Metaphysics Research Lab, Stanford University, 2022.

[6] P. Johnson-Laird, «Deductive reasoning,» *WIREs Cognitive Science*, vol. 1, n.º 1, pp. 8–17, 2010. DOI: https://doi.org/10.1002/wcs.20. eprint: https://wires.onlinelibrary.wiley.com/doi/pdf/10.1002/wcs.20. URL: https://wires.onlinelibrary.wiley.com/doi/abs/10.1002/wcs.20.

[7] A. D. Cling, «The Epistemic Regress Problem,» *Philosophical Studies: An International Journal for Philosophy in the Analytic Tradition*, vol. 140, pp. 401–421, 3 2008. DOI: 10.1007/s1. URL: https://about.jstor.org/terms.

[8] L. Henderson, «The Problem of Induction,» em *The Stanford Encyclopedia of Philosophy*, E. N. Zalta, ed., Spring 2020, Metaphysics Research Lab, Stanford University, 2020.

[9] H. Lin, «Bayesian Epistemology,» em *The Stanford Encyclopedia of Philosophy*, E. N. Zalta e U. Nodelman, eds., Fall 2022, Metaphysics Research Lab, Stanford University, 2022.

[10] J. Sprenger e S. Hartmann, *Bayesian Philosophy of Science*. Oxford University Press, ago. de 2019, ISBN: 9780199672110. DOI: 10.1093/oso/9780199672110.001.0001.

[11] G. Box, *Robustness in the Strategy of Scientific Model Building*. Academic Press, 1979, pp. 201–236, ISBN: 0124381502. DOI: 10.1016/b978-0-12-438150-6.50018-2. URL: http://dx.doi.org/10.1016/B978-0-12-438150-6.50018-2.

[12] F. Graybill e H. Iyer, *Regression Analysis: Concepts and Applications* (An Alexander Kugushev book). Duxbury Press, 1994, ISBN: 9780534198695.

[13] T. Morlot, C. Perret, A. C. Favre e J. Jalbert, «Dynamic rating curve assessment for hydrometric stations and computation of the associated uncertainties: Quality and station management indicators,» *Journal of Hydrology*, vol. 517, pp. 173–186, set. de 2014, ISSN: 00221694. DOI: 10.1016/j.jhydrol.2014.05.007.

[14] K. R. Popper, *Os dois problemas fundamentais da teoria do conhecimento*. Editora Unesp, 2013.

[15] K. R. Popper, *A lógica da pesquisa científica*. Editora Cultrix, 2004.

[16] B. C. v. Fraassen, *The Scientific Image*. Oxford University Press, dez. de 1980, ISBN: 9780198244271. DOI: 10.1093/0198244274.001.0001. URL: https://doi.org/10.1093/0198244274.001.0001.

[17] E. Agazzi, «The Truth of Theories and Scientific Realism,» em *Varieties of Scientific Realism: Objectivity and Truth in Science*, E. Agazzi, ed. Cham: Springer International Publishing, 2017, pp. 49–68, ISBN: 978-3-319-51608-0. DOI: 10.1007/978-3-319-51608-0_3. URL: https://doi.org/10.1007/978-3-319-51608-0_3.

[18] N. Cartwright, *How the Laws of Physics Lie* (Clarendon paperbacks). Clarendon Press, 1983, ISBN: 9780198247043. URL: https://books.google.com.br/books?id=lIQKFs0%5C_s18C.

[19] B. Monton e C. Mohler, «Constructive Empiricism,» em *The Stanford Encyclopedia of Philosophy*, E. N. Zalta, ed., Summer 2021, Metaphysics Research Lab, Stanford University, 2021.

[20] K. Stanford, «Underdetermination of Scientific Theory,» em *The Stanford Encyclopedia of Philosophy*, E. N. Zalta e U. Nodelman, eds., Summer 2023, Metaphysics Research Lab, Stanford University, 2023.

[21] D. Tulodziecki, «Underdetermination,» em *The Routledge Handbook of Scientific Realism*, J. Saatsi, ed. Taylor & Francis, 2017, pp. 60–71.

[22] J. Saatsi, *The Routledge Handbook of Scientific Realism* (Routledge Handbooks in Philosophy). Taylor & Francis, 2017, ISBN: 9781351362900.

[23] D. D. Hoffman, M. Singh e C. Prakash, «The Interface Theory of Perception,» *Psychonomic Bulletin and Review*, vol. 22, pp. 1480–1506, 6 dez. de 2015, ISSN: 15315320. DOI: 10.3758/s13423-015-0890-8.

[24] D. D. Hoffman, C. Prakash e R. Prentner, «Fusions of Consciousness,» *Entropy*, vol. 25, 1 jan. de 2023, ISSN: 10994300. DOI: 10.3390/e25010129.

[25] O. N., S.-F. K. e K. Belitz, «Verification, Validation, and Confirmation of Numerical Models in the Earth Sciences,» *Science*, vol. 263, pp. 641–646, 5147 1994.

[26] K. Beven, «A manifesto for the equifinality thesis,» *Journal of Hydrology*, vol. 320, pp. 18–36, 1-2 mar. de 2006, ISSN: 00221694. DOI: 10.1016/j.jhydrol.2005.07.007.

[27] K. Beven, «On the concept of model structural error,» *Water Science and Technology*, vol. 52, pp. 167–175, 6 2005. URL: https://iwaponline.com/wst/article-pdf/52/6/167/434056/167.pdf.

[28] K. Beven, «Facets of uncertainty: Epistemic uncertainty, non-stationarity, likelihood, hypothesis testing, and communication,» *Hydrological Sciences Journal*, vol. 61, pp. 1652–1665, 9 jul. de 2016, ISSN: 21503435. DOI: 10.1080/02626667.2015.1031761.

[29] A. Tarantola, «Popper, Bayes and the inverse problem,» *Nature Physics*, vol. 21, pp. 492–494, 2006.